康奈尔学习笔记：Over- and Under-determined Analytic Regression

超定与欠定解析回归

日期 / Date： 2026-10-03
科目 / Subject： EE6406 Analytic and Ensemble Machine Learning
资料 / Sources： Lecture 5 课件（59 个 PDF pages）与课堂转录 `61031`、`68595`；第二份转录开头承接本讲 kernel 部分。

> **本讲主线：** 选择 feature map $p(x)$ → 形成 P 与目标 y/Y → 由 m 和 $D+1$ 选择 primal 或 dual 空间 → 用 SSE 或 ridge 求闭式解 → 用 P_t 或 kernel matrix 预测 → threshold / argmax 得到类别。

📚 学习导航与资料边界

学习目标	笔记位置	资料依据
从 SSE 推导 over-determined analytic regression	§2–§3	6406/materials/EE6406-Lecture5-TKA-v2.pdf PDF pages 5–20
理解 under-determined 的 subspace / least-norm 解	§4	课件 PDF pages 21–28
区分 primal 与 dual ridge regression	§5	课件 PDF pages 29–40
掌握 kernel regression 与 kernel ridge	§6	课件 PDF pages 41–53
把连续输出变成 binary / multi-category decision	§7	课件 PDF pages 54–57
复算所有课件例题	§3.4、§4.4、§5.3、§6.5、§7.3、§9	Examples 5.1–5.4
保留课堂考试边界与实现提醒	§8	两份课堂转录

前置： L3：Linear Parametric Models · L4：Learning Score Functions
后续： L6：Advanced Analytic Classification
总索引： 6406/notes/EE6406_课程笔记索引.md

本笔记怎么读

阅读目标	建议顺序	读完应能回答
先建立全局图	§1 → §2	P 的行、列分别代表什么？为什么先看 shape?
学会选公式	§3 → §5	什么时候用 P^TP，什么时候用 PP^T，ridge 改了什么?
真正理解欠定解	§4.1–§4.3	为什么有无穷多解？minimum norm 到底选了哪一个?
理解 kernel	§6	K 和 K_t 的每个元素、每一行分别代表什么?
完成分类决策	§7	regression scores 怎样变成 binary 或 multi-class label?
考前复习	§10–§14	能按 shape 选解，并检查 rank、threshold 与输出维度

> **本讲只抓一条因果链：** 每个样本先变成一行 features → 所有行组成 P → P 的 shape 决定在哪个空间求逆 → 求得参数或 dual coefficients → 对 test rows 产生 scores → threshold / argmax 产生类别。

线索栏（Cornell Questions）

1. 为什么同一个 SSE objective 会产生 primal 与 dual 两种解?
2. $P \in \mathbb{R}^{m\times(D+1)}$ 的行、列各代表什么?
3. Over-determined SSE 的 normal equation 怎样得到?
4. Under-determined system 为什么把 w 写成 $P^T\alpha$?
5. Least-norm solution 到底在无穷多解中选了什么?
6. Ridge 中的 λI 为什么改善稳定性?
7. Primal 与 dual ridge 应怎样按 inverse size 选择?
8. Gram matrix K 与 test kernel matrix K_t 的 shape 是什么?
9. Kernel trick 为什么不需要显式列出 polynomial features?
10. Kernel regression 与 kernel ridge 的差别是什么?
11. Binary threshold 与 multi-category argmax 怎样把 regression output 变成类别?
12. L5 的考试计算最先应检查什么?

---

1. Knowledge Framework / 知识点框架

```
Training data (X, y or Y)
        ↓ choose feature map p(x)
P ∈ R^{m×(D+1)}
        ↓ compare sample size m with feature dimension D+1
        ├─ m > D+1: primal / over-determined
        │     LS:    (PᵀP)⁻¹Pᵀy
        │     ridge: (PᵀP+λI)⁻¹Pᵀy
```

```
        └─ m < D+1: dual / under-determined
              w = Pᵀα
              LS:    Pᵀ(PPᵀ)⁻¹y
              ridge: Pᵀ(PPᵀ+λI)⁻¹y
                        ↓
              replace inner products by kernels
                        ↓
Prediction: P_t w or K_t α
       ↓
binary threshold / multi-class argmax
```

符号	Shape	含义
X	$m \times d$	m 个原始输入样本，每个有 d 个 features
$p(x_i)$	$(D+1) \times 1$	含 intercept 的 transformed feature column
P	$m \times (D+1)$	第 i 行为 $p^T(x_i)$
y	$m \times 1$	单输出 target vector
Y	$m \times C$	C 类 one-hot / indicator targets
w	$(D+1) \times 1$	primal parameter vector
W	$(D+1) \times C$	多输出参数矩阵
α	$m \times 1$	dual coefficients
$K = PP^T$	$m \times m$	training Gram / kernel matrix
K_t	$n \times m$	n 个 test samples 对 m 个 training samples 的 kernels

先把三个容易混淆的对象分开

假设有 $m = 3$ 个样本，每个样本映射后有 $D + 1 = 2$ 个特征，并做 $C = 2$ 类分类：

$$P = \begin{bmatrix} 1 & 0.2 \\ 1 & 1.1 \\ 1 & -0.4 \end{bmatrix}, \qquad Y = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

- P 的第 i 行是第 i 个样本的 transformed features；
- Y 的第 i 行是**同一个样本**的 target；
- W 的第 k 列负责产生第 k 类 score；
- PW 的第 i 行给出第 i 个样本对所有类别的 scores。

样本可以按任意顺序排列。真正不能改变的是：**P 与 Y 的相同行必须指向同一个样本。**

2. Regression Error Based Learning / 基于回归误差的学习

2.1 问题与模型（What）

给定 m 个 training pairs (x_i, y_i)，目标不是记住训练样本，而是得到能预测 unseen data 的 inference engine。课程把 predictor 写成对参数线性的形式：

$$g(x_i, w) = w^T p(x_i),$$

其中 $p(x_i) = [1, p_1(x_i), \ldots, p_D(x_i)]^T$ 可以是线性或非线性 feature map；模型可以对 x 非线性，但对 w 仍是线性的。

Least Squares Error（LSE）最小化 Sum of Squared Errors（SSE）：

$$J_{SSE}(w) = \sum_{i=1}^{m} \left(y_i - g(x_i, w)\right)^2 = \|y - Pw\|_2^2.$$

把这个式子翻成普通话：

1. Pw 同时算出全部 training predictions；
2. $y - Pw$ 的第 i 个元素是第 i 个样本的 residual；
3. $\|y - Pw\|_2^2$ 把所有 residual 平方后相加；
4. 学习就是寻找使这笔总误差最小的 w。

2.2 为什么先检查 shape（Why）

真正需要求逆的矩阵取决于把问题放在哪个空间：

- $P^T P$ 的 shape 是 $(D+1) \times (D+1)$，属于 feature space；
- PP^T 的 shape 是 $m \times m$，属于 sample space；
- 应优先在较小空间求解，同时必须满足相应的 rank / nonsingularity 条件。

课堂明确强调： 计算前先写 P 的 rows 与 columns，再判断 over- / under-determined。若只背公式而不检查 inverse 的 shape，很容易把 primal 与 dual 公式用反。

---

3. Over-determined SSE / 超定系统的最小二乘

3.1 Normal equation 怎样得到（How）

对

$$J_{SSE}(w) = (y - Pw)^T (y - Pw)$$

求 gradient：

$$\nabla_w J_{SSE}(w) = -2P^T (y - Pw).$$

令 gradient 为零：

$$P^T P w = P^T y.$$

当 $P^T P$ nonsingular 时：

$$\boxed{\hat{w} = (P^T P)^{-1} P^T y.}$$

通常 $m > D + 1$ 称 over-determined；课件在公式页写 $m \geq D + 1$ 并同时要求 observations independent、$P^T P$ nonsingular。后一个条件才真正保证 inverse 存在。

补充理解：用 3 个点拟合一条直线

令

$$P = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad y = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

P 有 3 行、2 列，表示用 3 个 observations 估计截距与斜率两个参数。于是：

$$P^T P = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \qquad P^T y = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

代入 normal equation：

$$\hat{w} = (P^T P)^{-1} P^T y = \begin{bmatrix} 7/6 \\ 1/2 \end{bmatrix}.$$

因此拟合直线为 $\hat{y} = 7/6 + (1/2)x$。三个预测值不是逐点等于 y，因为 3 条约束一般无法由 2 个参数全部满足；least squares 选择的是**总体 squared residual 最小**的折中解。

3.2 Training 与 test prediction

训练输出与测试输出分别是：

$$\hat{g}(X) = P\hat{w}, \qquad \hat{g}(X_t) = P_t \hat{w}.$$

$P_t \in \mathbb{R}^{n\times(D+1)}$ 必须使用与 training 完全相同的 feature map 和列顺序。

3.3 Multi-category extension

把每一类的 indicator target 作为 Y 的一列：

$$J_{SSE}(W) = \operatorname{trace}\left[(Y-PW)^T(Y-PW)\right].$$

每一列共享同一个 P，因此可一次写成：

$$\boxed{\hat{W} = (P^TP)^{-1}P^TY.}$$

这不是新的求解原理，只是把 C 个独立的 least-squares problems 横向堆叠。

为什么课件把 Y 写成 category blocks?

若有三类，one-hot rows 分别是：

$$\text{class } 1 : [1,0,0], \quad \text{class } 2 : [0,1,0], \quad \text{class } 3 : [0,0,1].$$

课件为了画图方便，常把同类样本连续堆成 Y_1, Y_2, Y_3，并把 P 的对应 rows 也按相同顺序堆叠。这个分块**不是算法要求**。例如样本顺序为 class 2、class 1、class 3、class 2 时，可以写成：

$$Y = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}.$$

只要 P 的四行也按这四个样本的同一顺序排列，PW 与 Y 就能逐行比较。**需要的是 row correspondence，不需要按类别排序。**

3.4 Example 5.1(a) — 二阶多项式超定学习

课件给出 10 个二维训练样本，三类 targets 分别为前 4 个、中间 4 个、最后 2 个样本。采用：

$$p(x_1,x_2) = [1, x_1, x_2, x_1^2, x_1x_2, x_2^2]^T.$$

因此 $m = 10$、$D+1 = 6$，$P \in \mathbb{R}^{10\times 6}$，属于 over-determined system。两个 test points 是 $(-1, 3.3)$ 与 $(2.5, 0.5)$。

课件计算：

$$\hat{W} = (P^T P)^{-1} P^T Y,$$

并得到 test scores：

$$\hat{G}_t = \begin{bmatrix} 0.3080 & 0.6892 & 0.0028 \\ -0.5763 & 1.4049 & 0.1714 \end{bmatrix}.$$

两行尚是 regression scores；最终类别要等到 §7 再由 row-wise argmax 决定。

---

4. Under-determined SSE / 欠定系统与最小范数解

4.1 为什么 primal inverse 失败

若 $m < D+1$，则 P 最多只有 m 个 independent rows，故 $P^T P$ 的 rank 不超过 m，通常 singular。此时未知参数多于独立约束，一致系统一般有无穷多 exact solutions。

4.2 Subspace reparameterization

当 $m < D+1$ 时，方程 $Pw = y$ 的约束数量少于参数数量。若它一致，通常存在无穷多个解。任意一个解都可以写成：

$$w = w_{row} + w_{null},$$

其中 w_{null} 位于 P 的 null space，所以 $Pw_{null} = 0$。它不会改变 training output，却会增大参数 norm。minimum-norm solution 因而令 $w_{null} = 0$，只保留 P 的 row space 中的部分：

$$w = P^T \alpha, \qquad \alpha \in \mathbb{R}^m.$$

这里的 α 给每个 training row 一个组合权重。$P^T \alpha$ 把这 m 个 row directions 组合成 feature-space 参数 w。

代入 SSE 后在 sample space 调整 α：

$$\min_{\alpha} \|y - PP^T \alpha\|_2^2.$$

若 PP^T full rank：

$$\hat{\alpha} = (PP^T)^{-1} y,$$

所以：

$$\boxed{\hat{w} = P^T(PP^T)^{-1}y.}$$

4.3 为什么叫 least-norm solution

同一个结果也可由 constrained problem 得到：

$$\min_w \|w\|_2^2 \quad \text{subject to} \quad y - Pw = 0.$$

它不是说原系统只有一个解，而是在所有 exact solutions 中选 Euclidean norm 最小的一个。下面把课件 Slides 22–23 省略较快的步骤完整展开。

Step 1：**把约束放进** Lagrangian

为每条约束引入 multiplier α：

$$\mathcal{L}(w, \alpha) = \|w\|_2^2 + (y - Pw)^T\alpha.$$

α 不是新的模型参数，而是帮助强制执行 $y - Pw = 0$ 的 Lagrange multiplier vector。

Step 2：**对** w **求导**

展开第二项：

$$(y - Pw)^T\alpha = y^T\alpha - w^TP^T\alpha.$$

因此：

$$\frac{\partial \mathcal{L}}{\partial w} = 2w - P^T\alpha.$$

令一阶条件为零：

$$2w - P^T\alpha = 0 \quad \Longrightarrow \quad w = \frac{1}{2}P^T\alpha.$$

这一步解释了为什么最小范数解必然能写成 $P^T\alpha$。

Step 3：**代回原约束，先求** α

由 $y = Pw$：

$$
\begin{aligned}
y &= P\left(\frac{1}{2}P^T\alpha\right) \\
&= \frac{1}{2}PP^T\alpha.
\end{aligned}
$$

若 PP^T nonsingular：

$$
\hat{\alpha} = 2(PP^T)^{-1}y.
$$

Step 4：代回 w

$$
\begin{aligned}
\hat{w} &= \frac{1}{2}P^T\hat{\alpha} \\
&= \frac{1}{2}P^T\left[2(PP^T)^{-1}y\right] \\
&= \boxed{P^T(PP^T)^{-1}y}.
\end{aligned}
$$

补充理解：一个方程、两个未知数

若

$$
P = [1 \quad 1], \qquad y = 2,
$$

约束是 $w_1 + w_2 = 2$。$(0,2)$、$(1,1)$、$(3,-1)$ 都能 exact fit，但 norms 不同。用公式：

$$
\begin{aligned}
\hat{w} &= P^T(PP^T)^{-1}y \\
&= \begin{bmatrix}1\\1\end{bmatrix}\left([1\ 1]\begin{bmatrix}1\\1\end{bmatrix}\right)^{-1}2 \\
&= \begin{bmatrix}1\\1\end{bmatrix}\frac{1}{2}(2) = \begin{bmatrix}1\\1\end{bmatrix}.
\end{aligned}
$$

它在直线 $w_1 + w_2 = 2$ 上离原点最近，因此 norm 最小。

4.4 Example 5.2(a) — 三阶多项式欠定学习

课件取 6 个二维样本，并用 full third-order polynomial。二维三阶完整多项式含：

$$
\binom{2+3}{3} = 10
$$

个 terms，所以 $P \in \mathbb{R}^{6\times 10}$，$6 < 10$。选择 sample-space inverse：

$$
\boxed{\hat{W} = P^T(PP^T)^{-1}Y.}
$$

该例与 Example 5.1 使用相同两个 test points，差别在于训练样本更少、feature expansion 更高，因此必须转到 dual / sample space。

---

5. Ridge Regression / 岭回归

5.1 Primal ridge

当 large coefficients 使输出对小输入扰动过度放大时，在 SSE 后加入 weight decay：

$$J_{SSEr}(w) = \|y - Pw\|_2^2 + \lambda \|w\|_2^2, \qquad \lambda > 0.$$

令 gradient 为零：

$$-2P^T(y - Pw) + 2\lambda w = 0,$$

整理为：

$$(P^TP + \lambda I)w = P^Ty,$$

$$\boxed{\hat{w} = (P^TP + \lambda I)^{-1}P^Ty.}$$

λI 给 covariance matrix 的 diagonal 加正数，减少接近 singular 时的数值放大。权衡是：λ 增大通常使参数更小、variance 更低，但 bias 更大。

5.2 Dual ridge

从 primal normal equation 可得到 $w = P^T\alpha$，并令：

$$\hat{\alpha} = (PP^T + \lambda I)^{-1}y.$$

因此：

$$\boxed{\hat{w} = P^T(PP^T + \lambda I)^{-1}y.}$$

形式	求逆矩阵	适合的相对规模
Primal ridge	$(D+1) \times (D+1)$	$D+1$ 较小，常见于 over-determined
Dual ridge	$m \times m$	m 较小，常见于 under-determined

两式在成立条件下描述同一类 regularized solution；“dual”不是另一种 loss，而是换到 sample-coordinate α 中求解。

5.3 Examples 5.1(b) 与 5.2(b)

- **Example 5.1(b)：** 对 Example 5.1(a) 用 $\lambda = 0.001$ 的 primal ridge。test scores 变为

$$\hat{G}_t = \begin{bmatrix} 0.3085 & 0.6886 & 0.0053 \\ -0.5709 & 1.3915 & 0.1792 \end{bmatrix}.$$

- **Example 5.2(b)：** 对 under-determined example 用 dual ridge：

$$\hat{W} = P^T(PP^T + 0.001I)^{-1}Y,$$

test scores 为：

$$\hat{G}_t = \begin{bmatrix} -0.7265 & 1.7717 & 0.1343 \\ 0.3231 & 0.6092 & 0.2091 \end{bmatrix}.$$

两例的预测类别相同，但 score 数值不同，说明 regularization 改变的是 fitted surface，而不是预先保证某个 class label。

---

6. Kernel Regression / 核回归

6.1 从 dual inner product 到 kernel

在 dual form 中，预测只通过 training features 的 inner products 使用 P：

$$w = P^T\alpha, \qquad g(x) = \alpha^T P p(x).$$

定义 training kernel matrix：

$$K = PP^T \in \mathbb{R}^{m\times m},$$

以及 test kernel matrix：

$$K_t = k(P_t, P) \in \mathbb{R}^{n\times m}.$$

若 kernel function 可直接计算 $k(x_i, x_j) = p(x_i)^T p(x_j)$，就无需显式构造可能极高维的 $p(x)$。例如 polynomial kernel：

$$k(x_i, x) = (1 + x_i^T x)^r.$$

把矩阵按“谁和谁比较”来读：

- K 的第 i 行、第 j 列是 training sample x_i 与 x_j 的相似度；
- K_t 的第 r 行、第 j 列是 test sample $x_{t,r}$ 与 training sample x_j 的相似度；
- 因此 K_t 必须有 m 列，才能与长度为 m 的 α 相乘。

Kernel trick 省掉的是显式 feature expansion，不是省掉 training samples 之间的 pairwise comparisons。

6.2 Kernel regression

未正则化时：

$$\hat{\alpha} = K^{-1} y, \qquad \boxed{\hat{y}_t = K_t K^{-1} y.}$$

条件是 K nonsingular；这在实际数据中不总能保证。

6.3 Kernel ridge regression

把 $\|w\|_2^2 = \alpha^T K \alpha$ 写进 dual objective：

$$J(\alpha) = \frac{\lambda}{2} \alpha^T K \alpha + \frac{1}{2} (y - K\alpha)^T (y - K\alpha).$$

课件推导得到：

$$\hat{\alpha} = (K + \lambda I)^{-1} y,$$

所以：

$$\boxed{\hat{y}_t = K_t (K + \lambda I)^{-1} y.}$$

多输出时只需以 Y 代替 y：

$$\hat{G}_t = K_t (K + \lambda I)^{-1} Y.$$

6.4 Gaussian kernel 的 σ

课件 Example 5.3 使用：

$$K_{ij} = \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right).$$

- 小 σ：相似度衰减快，prediction 更局部、更容易起伏；
- 大 σ：相似度衰减慢，曲线更平滑，也可能抹去局部结构。

课堂特别强调 σ 会直接改变 kernel fit；它不是无关的作图参数。

6.5 Examples 5.3–5.4

Example 5.3：Gaussian kernel

1. 由 training inputs 形成 K；
2. 计算 $\hat{\alpha} = (K + \lambda I)^{-1} y$；
3. training output 为 $K\hat{\alpha}$；
4. 对 test inputs 形成 K_t；
5. test output 为 $K_t\hat{\alpha}$。

Example 5.4：**五阶** polynomial kernel

课件直接按元素计算：

$$K = (\mathbf{1} + XX^T)^{\circ 5},$$

其中 $\circ 5$ 表示每个 matrix element 分别取五次幂，$\mathbf{1}$ 是 $m \times m$ 全 1 matrix。重点是不用枚举五阶 polynomial expansion 的全部 monomials。

---

7. From Regression Output to Classification / 从回归输出到分类

7.1 Binary threshold

若 targets 为 $\{0, 1\}$，常在 normalized score 上用 $\tau = 0.5$；若 targets 为 $\{-1, +1\}$，常用 $\tau = 0$：

$$\text{cls}(g(x, w)) = \begin{cases} 1, & g(x, w) > \tau, \\ 0, & g(x, w) < \tau. \end{cases}$$

等号落在哪一类必须在实现中明确；课件公式只写了严格大于与严格小于。

7.2 Multi-category winner-takes-all

对第 j 个 test sample，取 C 个 outputs 中最大的一个：

$$\boxed{\mathrm{cls}(g(x_j, W)) = \underset{k\in\{1,\ldots,C\}}{\mathrm{argmax}}\ g(x_j, w_k).}$$

课件把它称为 one-versus-all / winner-takes-all，并用 one-hot vector 输出类别。

7.3 Examples 5.1(c) 与 5.2(c)

对 Examples 5.1(b) 与 5.2(b) 的两行 test scores 分别做 argmax，均得到：

$$\hat{Y}_{t,\mathrm{class}} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

即第一个 test point 判为 class 2，第二个判为 class 3。

---

8. Lecture Additions / 课堂口头补充

8.1 Predictor 与 classifier 的措辞

老师说明 **predictor** 是更一般的术语，可以输出连续 regression value，也可以在后接 threshold / argmax 后用于 classification；**classifier** 则明确指类别决策系统。

8.2 本讲考试深度

课堂反复强调：

- L5 是把 L3 的 over- / under-determined systems 应用到 learning；
- 必须会先看 P 的 shape，再选 primal 或 dual formula；
- simple hand calculation 与课件 examples 要会；
- kernel 的关键是直接算 training-training 与 test-training similarities，不必显式求 $p(x)$；
- 长篇 primal-to-dual manipulation 用于理解来源，应用最终式与检查维度更重要。

8.3 理论 singular 与 numerical ill-conditioning

矩阵 theoretically invertible 不代表数值计算一定可靠。若 eigenvalues 跨越很大尺度，floating-point inversion 仍可能放大误差；λI 能改善 conditioning。实际代码宜用 linear solve，而不是显式 `inv`，但考试推导仍按课件 inverse 形式书写。

8.4 Source Coverage Audit / 逐页覆盖核对

PDF 页码	已覆盖内容	笔记位置
4–15	课程动机、SSE、超定与多输出闭式解	§2–§3
16–20	Example 5.1(a)：超定回归与分类输出	§3.4、§7
21–28	欠定系统、最小范数、Example 5.2(a)	§4
29–40	Ridge、primal/dual 形式与相关例题	§5
41–49	核表示、kernel trick、kernel ridge	§6.1–§6.4
50–53	kernel regression 数值例题	§6.5
54–57	二分类阈值、多分类 argmax	§7
58	全讲总结	§11–§14

✓ **Coverage conclusion**

Lecture 5 的 substantive slides、例题与课堂补充均已纳入；封面、目录和参考文献页不重复抄录。

---

9. All Slide Exercises / Questions / PPT 中出现的例题与课堂练习汇总

题目	简明答案	正文位置
Example 5.1(a)：10 samples、二阶 full polynomial	$P : 10 \times 6$，用 primal LS	3.4 Example 5.1(a) — 二阶多项式超定学习
Example 5.2(a)：6 samples、三阶 full polynomial	$P : 6 \times 10$，用 dual least-norm	4.4 Example 5.2(a) — 三阶多项式欠定学习
Examples 5.1(b), 5.2(b)	分别用 primal / dual ridge，$\lambda = 0.001$	5.3 Examples 5.1(b) 与 5.2(b)
课件问题：不显式形成 P，怎样得到 polynomial K?	直接按 $K_{ij} = (1 + x_i^T x_j)^r$ 计算 pairwise kernels	6.1 从 dual inner product 到 kernel
Example 5.3	Gaussian kernel → $K \to \alpha \to K_t\alpha$	6.5 Examples 5.3–5.4
Example 5.4	$K = (\mathbf{1} + XX^T)^{\circ 5}$，无需枚举 monomials	6.5 Examples 5.3–5.4
Examples 5.1(c), 5.2(c)	row-wise argmax 得 class 2 与 class 3	7.3 Examples 5.1(c) 与 5.2(c)

---

10. 高频对比题总表

方法	Objective / constraint	求逆空间	关键条件与作用
Primal LS	$\min\|y-Pw\|^2$	$D+1$	P^TP nonsingular
Dual least-norm	$\min\|w\|^2$ s.t. $y=Pw$	m	PP^T nonsingular；选 minimum-norm exact solution
Primal ridge	SSE $+\lambda\|w\|^2$	$D+1$	缩小参数并稳定 feature-space inverse
Dual ridge	同一 ridge problem 的 sample-space form	m	在 m 较小时更经济
Kernel regression	kernel-space SSE	m	需 K nonsingular
Kernel ridge	kernel SSE + regularization	m	用 $K+\lambda I$ 提高稳定性

---

11. Exam-Focused Formula Sheet / 考试公式页

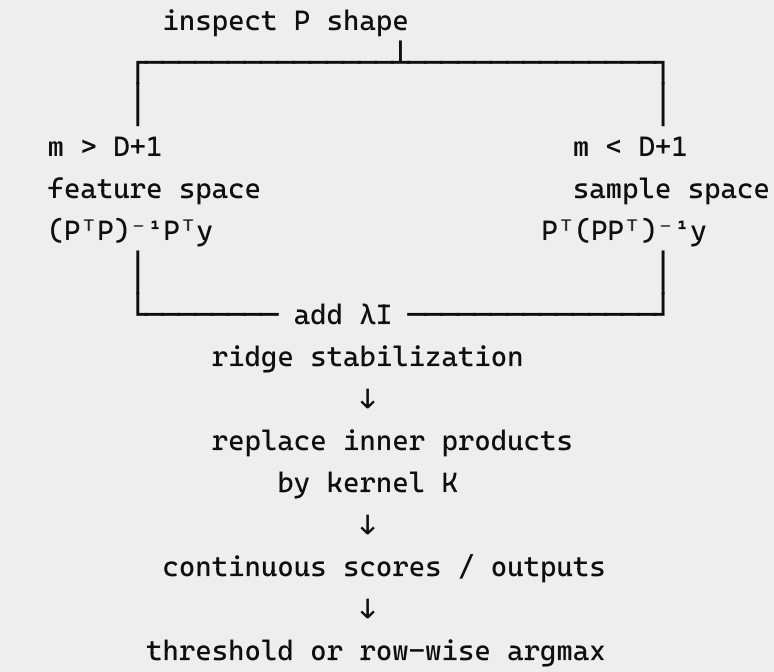
$$
\begin{aligned}
J_{SSE}(w) &= \|y-Pw\|_2^2, \\
\hat{w}_{\text{primal LS}} &= (P^TP)^{-1}P^Ty, \\
\hat{w}_{\text{dual LS}} &= P^T(PP^T)^{-1}y, \\
\hat{w}_{\text{primal ridge}} &= (P^TP+\lambda I)^{-1}P^Ty, \\
\hat{w}_{\text{dual ridge}} &= P^T(PP^T+\lambda I)^{-1}y, \\
\hat{\alpha}_{\text{kernel ridge}} &= (K+\lambda I)^{-1}y, \\
\hat{y}_t &= K_t\hat{\alpha}.
\end{aligned}
$$

检查项	必须写清
P shape	$m\times(D+1)$
Primal inverse	$(D+1)\times(D+1)$
Dual / kernel inverse	$m\times m$
K_t shape	$n\times m$，test rows × training columns
Multi-class decision	每个 test row 对 class columns 做 argmax

---

12. 一页速记 / One-Page Memory Map

```
SSE + linear-in-parameter model
            ↓
```



---

13. Cornell Questions — 答案

Q1. 为什么 SSE 会产生 primal 与 dual 两种解?

同一模型可直接在 feature parameter w 中求解，也可令 $w = P^T\alpha$ 后在 sample coefficients α 中求解；两种形式选择不同大小的 inverse space。

Q2. P 的行、列各是什么?

每一行对应一个 training sample 的 transformed features，每一列对应一个 basis / polynomial / mapped feature term，含 intercept 共 $D+1$ 列。多输出时，Y 的第 i 行必须是同一个样本的 target；样本不必按类别排序，但 P 与 Y 的 row correspondence 不能错位。

Q3. Over-determined normal equation?

对 $\|y - Pw\|^2$ 求 gradient 并令其为零，得到 $P^TPw = P^Ty$；若 P^TP nonsingular，则 $\hat{w} = (P^TP)^{-1}P^Ty$。

Q4. 为什么写 $w = P^T\alpha$?

Under-determined 时 feature space 比 sample space 大。该表示把 w 限制在 training rows 张成的空间，并把求解降到 m 维。

Q5. Least-norm 选什么?

在所有满足 $Pw = y$ 的 exact solutions 中，选择 $\|w\|_2$ 最小的一个；其余解可含不改变输出的 null-space component。由 Lagrangian 的一阶条件得到 $w = \frac{1}{2}P^T\alpha$，代回约束后得到 $\hat{w} = P^T(PP^T)^{-1}y$。

Q6. λI 为什么稳定?

它把 covariance / Gram matrix 的 eigenvalues 向正方向平移，减少接近零 eigenvalue 导致的 inverse amplification，同时以 bias 换取较低 variance。

Q7. 怎样选 primal 或 dual ridge?

比较 $D+1$ 与 m，优先求逆较小矩阵：feature dimension 小用 primal，sample size 小用 dual，并检查数据结构与条件数。

Q8. K 与 K_t 的 shape?

$K \in \mathbb{R}^{m\times m}$；$n$ 个 test samples 时，$K_t \in \mathbb{R}^{n\times m}$。

Q9. Kernel trick 为什么不列 features?

因为 dual prediction 只依赖 $p(x_i)^T p(x_j)$；若 kernel function 能直接计算这个 inner product，就无需构造 $p(x)$ 本身。

Q10. Kernel regression 与 kernel ridge 的差别?

前者用 $K^{-1}y$，要求 K nonsingular；后者用 $(K+\lambda I)^{-1}y$，同时做 coefficient shrinkage 与 numerical stabilization。

Q11. 怎样从 scores 得到类别?

Binary 用 threshold；multi-category 对每个样本的 class-score row 取 argmax，再按需要写成 class index 或 one-hot vector。

Q12. 考试计算最先检查什么?

先写 m、$D+1$ 与 P 的 shape，再判断 inverse 应落在 P^TP 还是 PP^T；之后才代公式。

---

14. 总结栏（Review）

Lecture 5 把 L3 的线性系统真正变成 learning algorithm：SSE 决定 normal equation，数据与 feature map 决定 P 的 shape，shape 决定在 feature space 还是 sample space 求解。Ridge 通过 λI 控制参数并改善 conditioning；kernel 则把 dual form 中的 inner products 直接换成 similarity function。最后的 threshold / argmax 只是把连续 score 转为类别，不能与前面的参数学习混为一谈。

一句话记忆

> **先看 P 的 shape 选 primal 或 dual，再加 λI 稳定求解；kernel 只是把 dual inner product 隐式化。**