康奈尔学习笔记：Advanced Analytic Classification

高级解析分类：TER、AUC 与统一框架

日期 / Date： 2026-10-03
科目 / Subject： EE6406 Analytic and Ensemble Machine Learning
资料 / Sources： Lecture 6 课件（59 个 PDF pages）与课堂转录 `68595`、`70764`；后一份转录开头补完本讲 generalized framework。

> **本讲主线：** Classification counting objective 不可导 → 用 shifted quadratic 只工作在单侧区间 → TER 得到 class-balanced closed form → AUC 把所有正负样本组成 pairs 并优化 ranking → data scaling / translation 把 TER、AUC、FLD、weighted LS 与 LSE 放进同一框架。

📚 学习导航与资料边界

学习目标	笔记位置	资料依据
从 FPR/FNR 建立 TER learning objective	§2–§4	6406/materials/EE6406-Lecture6-TKA-v1.pdf PDF pages 5–25
理解 shifted quadratic approximation	§3	课件 PDF pages 8–16；课堂转录
从 pairwise ranking 建立 AUC/AAC learning	§5	课件 PDF pages 26–36
理解 TAUC data transformation 的统一作用	§6	课件 PDF pages 37–48
连接 Gaussian likelihood 与 TER	§7	课件 PDF pages 49–55
区分考试必会计算与概念性推导	§8	两份课堂转录
复算全部课件例题	§4.5、§5.5、§9	Examples 5.4–5.5

前置： L4：Learning Score Functions · L5：Analytic Regression
后续： L7：Penalized Learning
总索引： 6406/notes/EE6406_课程笔记索引.md

本笔记怎么读

阅读目标	建议顺序	先抓住什么
理解 TER	§2 → §3 → §4	两类错误先统一成“残差大于 0”，再用单侧 quadratic 近似
理解 AUC	§5.1 → §5.4	AUC 比较的是正负样本的相对顺序，不是固定 threshold 下的分类数
看懂复杂闭式解	§4.1、§5.3	inverse 左边汇总二阶信息，右边汇总希望参数朝哪个方向移动
理解统一框架	§6	scaling、translation、centering 改的是数据表示，不必背完整 TAUC 长式
考前复习	§10–§14	能区分 TER、AUC、FLD、weighted LS 的数据单位和 threshold 角色

> **本讲的两条主线：** TER 问“固定 threshold 下两类各错多少”；AUC 问“任取一正一负，正样本是否排在负样本前面”。两者都把不易优化的 counting objective 改写为可解析求解的 quadratic objective。

线索栏（Cornell Questions）

1. 为什么直接优化 classification count 会变成 nonlinear / non-differentiable problem?
2. TER 为什么比普通 error rate 更适合 class imbalance?
3. ϵ_j 与 $_i$ 怎样把 FPR/FNR 写成同一方向的 loss?
4. Sigmoid approximation 有哪两个 optimization problems?
5. Shifted quadratic 为什么必须只使用一个 arm?
6. TER closed form 中 m^+、m^-、τ、、b 各做什么?
7. AUC 与 AAC 的关系是什么?
8. AUC learning 为什么基于 m^+m^- 个 sample pairs?
9. AUC solution 没有 threshold，实际决策怎样选择 τ?
10. Data transformation 怎样把 AUC、TER、FLD 与 LSE 联系起来?
11. TER 为什么可解释为 weighted LS 与 dual-Gaussian regression?
12. 本讲哪些部分要会计算，哪些只需掌握概念?

---

1. Knowledge Framework / 知识点框架

```
Classification objective
├─ fixed threshold errors
│    └─ TER = FPR + FNR
│         ↓ counting loss is non-differentiable
│    shifted one-arm quadratic approximation
│         ↓
```

```
│    class-balanced closed-form TER solution
│
└─ all-threshold ranking
     └─ ROC → AUC
          ↓ maximize AUC ≡ minimize AAC
     pairwise positive-negative differences
          ↓ shifted one-arm quadratic
     closed-form AUC/AAC solution

Generalized view
data scaling + translation
     ├─ AUC / TAUC
     ├─ TER
     ├─ FLD (class-centered)
     └─ weighted LS / LSE
```

层级	处理对象	是否依赖单一 threshold
TER	$FPR + FNR$，分别对两类归一化	是
ROC	threshold 扫描产生的一组 operating points	扫描全部 thresholds
AUC	正样本 score 高于负样本 score 的 pairwise fraction	否
AAC	$1 - AUC$ 对应的错误排序 fraction	否

---

2. Total Error Rate / 总错误率目标

2.1 从 classification count 出发

设 positive 与 negative training samples 分别有 m^+、m^- 个，predictor 为 $g(x, w)$，threshold 为 τ。课程写：

$$TER = FPR + FNR.$$

展开为：

$$TER = \frac{1}{m^-}\sum_{j=1}^{m^-} \mathrm{cls}\Big(g(x_j^-, w) > \tau\Big) + \frac{1}{m^+}\sum_{i=1}^{m^+} \mathrm{cls}\big(g(x_i^+, w) < \tau\big).$$

每类先除以自己的 class size，所以两类在 objective 中等权；这与普通 population error 会被多数类主导不同。

补充理解：为什么类别不平衡时要分别归一化?

假设有 90 个 negative、10 个 positive。某分类器把 90 个 negative 全部判对，却把 10 个 positive 全部判错：

$$FPR = \frac{0}{90} = 0, \qquad FNR = \frac{10}{10} = 1.$$

普通 accuracy 是 90%，看起来很高；但：

$$TER = FPR + FNR = 1, \qquad HTER = \frac{TER}{2} = 0.5.$$

TER 没有让 90 个多数类样本淹没 10 个少数类样本，而是先在每个 class 内计算错误率，再把两类等权相加。

2.2 把两类错误统一成“变量大于 0”

定义：

$$\epsilon_j = g(x_j^-, w) - \tau, \qquad _i = \tau - g(x_i^+, w) - ,$$

其中 $\to 0$ 用于表示 strict inequality，实践中忽略。这样 false positive 与 false negative 都可写为某个变量大于 0 时 loss 为 1：

$$TER = \frac{1}{m^-} \sum_j L(\epsilon_j > 0) + \frac{1}{m^+} \sum_i L(_i > 0).$$

直觉是：无论原样本属于哪一类，都把“犯错方向”翻到数轴正侧，之后才能使用同一种 surrogate。

用一个 threshold $\tau = 0.5$ 的例子检查符号：

样本	score	原判定	统一后的变量	是否 > 0
negative	0.8	高于 threshold，false positive	$\epsilon = 0.8 - 0.5 = 0.3$	是，错误
negative	0.2	低于 threshold，正确	$\epsilon = 0.2 - 0.5 = -0.3$	否，正确
positive	0.1	低于 threshold，false negative	$= 0.5 - 0.1 = 0.4$	是，错误
positive	0.9	高于 threshold，正确	$= 0.5 - 0.9 = -0.4$	否，正确

因此，后面的统一 loss 只需判断一个量是否大于 0。

2.3 为什么直接优化很难

Zero-one / counting loss 在 threshold 处跳变，其他位置几乎处处 gradient 为 0。它准确表达最终计数目标，却不能给 gradient method 提供连续的局部方向。

---

3. Link-Loss Matching / 连接函数与损失配对

3.1 Sigmoid approximation 的局限

课件先给出 smooth sigmoid：

$$\sigma(\theta) = \frac{1}{1+e^{-\theta}}, \qquad > 0.$$

它可导，但课堂指出两个问题：

1. $\sum \sigma(w)$ 对 w 仍是 nonlinear，可能有 local solutions，结果依赖 initialization；
2. sigmoid 饱和区形成 local plateaus，gradient 很小，搜索可能缓慢。

3.2 为什么普通 quadratic 不像 counting loss

Linear link $g(x,w) = w^T p(x)$ 与 quadratic loss 可形成 convex problem 和 closed form；但 z^2 关于 0 对称，正负两侧都会随 $|z|$ 增大，无法保证“错误侧 loss 高、正确侧 loss 低”。

3.3 Shifted one-arm quadratic

解决办法不是让整个 quadratic 近似 step，而是先移动 data / residual，使所有需要比较的值落在 quadratic 的同一个 monotonic arm。TER approximation 为：

$$\min_w \left\{ \frac{1}{2m^-} \sum_{j=1}^{m^-} (\epsilon_j +)^2 + \frac{1}{2m^+} \sum_{i=1}^{m^+} (_i +)^2 \right\}$$

是 offset；因只使用一侧，quadratic output 才能随着“错误程度”单调变化。加入 weight decay 后：

$$\min_w \frac{b}{2}\|w\|_2^2 + \frac{1}{2m^-} \sum_j \left[w^T p(x_j^-) - \tau + \right]^2 + \frac{1}{2m^+} \sum_i \left[\tau - w^T p(x_i^+) + \right]^2.$$

例如取 $= 1$：

- 正确侧 residual 为 -0.8 时，$(r+)^2=(-0.8+1)^2=0.04$；
- 错误侧 residual 为 0.4 时，$(r+)^2=(0.4+1)^2=1.96$。

这时 residual 越向错误侧移动，quadratic penalty 越大。若同时使用 parabola 的左右两臂，就可能出现“离 threshold 很远但分类正确的样本反而被重罚”，因此课件强调 **one-arm matching**。

核心机制： TER 与 AUC 都使用“offset 后只落在 quadratic 的一个 arm”这一技巧。不能只背闭式解而不说明为什么需要 。

---

4. TER Closed-Form Learning / TER 闭式学习

4.1 Sample-sum form

记 $p_j^-=p(x_j^-)$、$p_i^+=p(x_i^+)$。先把 objective 对 w 求导：

$$
\begin{aligned}
0 = bw &+ \frac{1}{m^-}\sum_j p_j^- \left(p_j^{-T}w-\tau+\right) \\
&+ \frac{1}{m^+}\sum_i p_i^+ \left(p_i^{+T}w-\tau-\right).
\end{aligned}
$$

把所有乘 w 的项放在左边，其余常数项放在右边：

$$
Aw=c,
$$

其中：

$$
\begin{aligned}
A &= bI+\frac{1}{m^-}\sum_j p_j^- p_j^{-T}+\frac{1}{m^+}\sum_i p_i^+ p_i^{+T}, \\
c &= \frac{\tau-}{m^-}\sum_j p_j^- + \frac{\tau+}{m^+}\sum_i p_i^+ .
\end{aligned}
$$

若 A nonsingular，则 $\hat{w}=A^{-1}c$：

$$
\boxed{\hat{w}=\left[bI+\frac{1}{m^-}\sum_j p_j^- p_j^{-T}+\frac{1}{m^+}\sum_i p_i^+ p_i^{+T}\right]^{-1}\left[\frac{\tau-}{m^-}\sum_j p_j^- + \frac{\tau+}{m^+}\sum_i p_i^+\right].}
$$

整式可这样读：

- inverse 内部的 A 汇总 regularization 与两类样本的 outer products，描述“数据沿哪些 feature directions 分布”；
- 右侧的 c 汇总两类希望靠近的 target levels，描述“参数应朝哪个方向移动”；
- $1/m^-$ 与 $1/m^+$ 使两类贡献不由样本数量决定。

符号解释

- b：weight-decay strength；
- τ：classification threshold；
- ：quadratic offset；
- m：两类的样本数，用于 class-wise normalization；
- $p_j^- p_j^{-T}$：negative sample 的 outer product；positive 同理。

4.2 Compact matrix form

将 negative / positive rows 分别堆成 P_-、P_+，$\mathbf{1}$ 是相应长度的 all-ones vector：

$$\boxed{\hat{w} = \left(bI + \frac{1}{m^-} P_-^T P_- + \frac{1}{m^+} P_+^T P_+ \right)^{-1} \left(\frac{\tau -}{m^-} P_-^T \mathbf{1}_- + \frac{\tau +}{m^+} P_+^T \mathbf{1}_+ \right).}$$

这就是把两类分别加权的 ridge-like least squares。

4.3 Weighted-LS form

若 data rows 按 negative 再 positive 排列，构造 diagonal class weights：

$$M = M^- + M^+,$$

negative block 每个 diagonal entry 为 $1/m^-$，positive block 为 $1/m^+$。target vector 的两类常数分别是 $\tau -$ 与 $\tau +$。于是：

$$\boxed{\hat{w} = (bI + P^T M P)^{-1} P^T M y.}$$

4.4 Dual TER

令 $w = P^T M \alpha$，课程给出：

$$\hat{\alpha} = (bI + P P^T M)^{-1} y,$$

$$\boxed{\hat{w} = P^T M (bI + P P^T M)^{-1} y.}$$

多类别时是 C 个 one-versus-all TER problems；每个 class-specific P_k, M_k, y_k 的 row order 必须一致。

4.5 Example 5.4 — TER classification

Training points 与 labels：

$$X = \{(2,2),(1,2),(1,1),(3,1),(2,3)\},$$
$$y = \{1,0,1,0,0\}.$$

采用 third-order polynomial model，预测 $x_{t1} = (2.5, 4)$ 与 $x_{t2} = (1, 0)$。课件的 one-hot implementation 在 threshold 0 画 decision contour；这与使用显式 0.5 threshold 的 earlier example 不同。

解题顺序：

1. 对 train/test 使用相同 polynomial expansion；
2. 由 labels 形成 one-versus-all Y；
3. 按 class counts 构造 M；
4. 根据 feature/sample dimension 选择 primal 或 dual TER；
5. 计算 test scores，再按实现规定的 threshold / argmax 得类别。

---

5. AUC-Based Learning / 基于 AUC 的学习

5.1 为什么从 ROC 改成 AUC

ROC 是 threshold 扫描得到的一条 curve，不是单一 scalar objective。AUC 把 curve 汇总成 scalar，并有清楚的 pairwise ranking interpretation。

令：

$$_{ij} = g(x_i^+) - g(x_j^-).$$

若 $_{ij} > 0$，这对 positive-negative samples 排序正确。采用 tie 计 0.5 的 Heaviside function：

$$u() = \begin{cases} 1, & > 0, \\ 0.5, & = 0, \\ 0, & < 0. \end{cases}$$

于是：

$$AUC = \frac{1}{m^+ m^-} \sum_{i=1}^{m^+} \sum_{j=1}^{m^-} u(_{ij}).$$

补充理解：四个 pairs 手算 AUC

假设 positive scores 为 $\{0.9, 0.4\}$，negative scores 为 $\{0.6, 0.2\}$。共有 $2 \times 2 = 4$ 对：

Pair	比较	结果
0.9 vs 0.6	positive 更高	1
0.9 vs 0.2	positive 更高	1
0.4 vs 0.6	positive 更低	0
0.4 vs 0.2	positive 更高	1

所以：

$$AUC = \frac{1 + 1 + 0 + 1}{4} = 0.75.$$

这就是“随机抽一个 positive 和一个 negative，positive score 更高”的经验概率。

5.2 AUC 与 AAC

Maximize AUC 等价于 minimize Area Above the ROC Curve（AAC）：

$$AAC = \frac{1}{m^+ m^-} \sum_{i,j} u(-_{ij}).$$

对 linear-parametric predictor，课程使用 pairwise difference：

$$d_{ij} = p_j^- - p_i^+.$$

Quadratic approximation 加 offset 与 regularization：

$$\min_w \left\{ \frac{b}{2} \|w\|_2^2 + \frac{1}{2m^+ m^-} \sum_{i,j} (d_{ij}^T w +)^2 \right\}$$

当 normalized score differences 落在 $[-1,1]$ 时，课件说明 $=+1$ 才使 wrongly ranked pairs 的 quadratic output 高于 correctly ranked pairs； $=-1$ 会反向。

5.3 AUC/AAC closed form

令

$$A_{pair}=bI+\frac{1}{m^+m^-}\sum_{i,j}d_{ij}d_{ij}^T,\qquad c_{pair}=-\frac{}{m^+m^-}\sum_{i,j}d_{ij}.$$

一阶条件仍是 $A_{pair}w=c_{pair}$，因此：

$$\boxed{\hat{w}=\left[bI+\frac{1}{m^+m^-}\sum_{i,j}d_{ij}d_{ij}^T\right]^{-1}\left[-\frac{}{m^+m^-}\sum_{i,j}d_{ij}\right].}$$

它一次求得在 pairwise ranking sense 下的 least-squares optimum，不需要在训练式中先选一个 threshold。

与 TER 对照：TER 累积的是 single-sample outer products；AUC 累积的是 positive-negative difference 的 outer products。公式外形相似，但训练单位不同。

5.4 训练无 threshold，部署仍要 threshold

AUC 对所有 operating thresholds 的排序表现负责，但实际 binary decision 必须选一个 operating point。课件用 approximated TER 给出：

$$\boxed{\tau=\frac{1}{2m^-}\sum_{j=1}^{m^-}\hat{w}^Tp_j^-+\frac{1}{2m^+}\sum_{i=1}^{m^+}\hat{w}^Tp_i^+.}$$

它是两类平均 scores 的中点。若应用代价不对称，实际 threshold 仍可能按安全、医疗或商业要求调整。

5.5 Example 5.5

课件沿用 Example 5.4 的 two-class points，通过 positive-negative pair differences 建立 AAC quadratic objective，然后产生 decision contours。该例的关键不是背图形，而是能写出：

```
split positive / negative
        ↓
form every d_ij = p_j^- - p_i^+
        ↓
```

```
accumulate d_ij d_ij^T and d_ij
        ↓
solve w_hat
        ↓
choose threshold for an operating point
```

---

6. Generalized Learning by Data Transformation / 数据变换统一框架

6.1 Transformation 的对象

对 raw feature：

$$\tilde{x} = Tx + a.$$

对 generalized feature：

$$\tilde{p}(x) = Tp(x) + a.$$

T 做 scaling / rotation / linear transformation，a 做 translation。若有 K 组 (T_k, a_k)，每个 original sample 可产生 K 个 transformed samples，代价是 computation 增加。

这一节不要先陷入参数表。先把 transformation 看成“换一套比较数据的方式”：

- **Scaling**：改变不同类别或方向的相对权重；
- **Translation**：把数据移到新的参考中心；
- **Centering**：令 a 与 class mean 有关，使公式关注类内散布而不是原始坐标；
- **多组 transformation**：让同一原始样本以多种视角参与 objective。

6.2 TAUC 为什么能统一其他方法

Transformed AUC（TAUC）在每个 pair difference 上再累加 K 组 transformations。改变 class-dependent scaling parameters $\beta_{k,\,k}$ 和 translations u_k, v_k，可让某些 terms 保留、消失或变成 class-centering。

设置变化	得到的关系	直觉
所有 class scalings 都为 1、无 translation	TAUC → AUC	不再改变 pairwise data
$_1 = \beta_2 = 0$，$\beta_1 = {}_2 = 1$	TAUC → TER-like	pairwise double sum 分解为 class-wise single sums

设置变化	得到的关系	直觉
加 class mean translations	TAUC → FLD-like	把每类 data 中心化后比较 mean separation
写成 P^TMP 与 P^TMy	TER → weighted LS	class-normalized weights 进入 LS

6.3 FLD 与 TER 的中心化差别

课件的特殊设置得到：

$$\hat{w} = \left[\frac{1}{m^-}\sum_j (p_j^- - {}^-)(p_j^- - {}^-)^T + \frac{1}{m^+}\sum_i (p_i^+ - {}^+)(p_i^+ - {}^+)^T\right]^{-1}({}^+ - {}^-).$$

与 TER 相比，FLD-like form 明确减去 class means；课堂将其概括为 **FLD 是 centered，TER 是 non-centered**。

学习边界： generalized framework 的长式用于展示方法间的结构关系。课堂明确说不要求记住整张复杂参数表；应掌握 scaling、translation、class-centering 如何把一个 formulation 化为另一个。

---

7. Relationship with Bayesian Inference / 与贝叶斯推断的联系

7.1 Regression likelihood

若：

$$y_i = x_i^T w + e_i, \qquad e_i \sim N(0, \sigma^2),$$

且 samples independent，则：

$$p(y \mid X, w) = (2\sigma^2)^{-m/2} \exp\left[-\frac{1}{2\sigma^2}(y - Xw)^T(y - Xw)\right].$$

Maximizing this likelihood 等价于 minimizing SSE。若再给 w Gaussian prior，posterior mean 会出现 covariance term 加 prior precision 的 ridge-like structure。

7.2 TER 的 dual-Gaussian interpretation

TER quadratic approximation 把 negative 与 positive 分别拉向两个 constant targets：

$$y^- = \tau -, \qquad y^+ = \tau +.$$

两类可分别看作不同 Gaussian error groups，再将 likelihood 相乘。若两类 variances 不同，它们自然产生不同 class weights。这解释了 TER closed form 为什么像 two-group weighted regression。

7.3 AUC 的 pairwise Gaussian interpretation

AUC/AAC 的“输入”不是单个 x，而是 pairwise difference $x_j^- - x_i^+$；因此其 quadratic approximation 可视为在 pairwise differences 上做 Gaussian regression。TAUC 则对应这些 differences 的 scaled / translated version。

---

8. Lecture Additions / 课堂口头补充

8.1 CA2 范围与深度

课堂通知说明 CA2 scope 为 Lectures 5–7。题目以 concept 为主，含可手算的 basic calculations；课件 examples 与教材后简单练习足够，不要求复杂 book computations。

8.2 L6 的优先级

- **需要较详细掌握：** TER、AUC 的目标、one-arm shifted quadratic、核心 closed forms、简单计算；
- **需要概念掌握：** generalized framework 中 scaling / translation / centering 如何连接方法；
- **不要求死背：** TAUC 展开的长 double/triple sums 和整张参数设置表。

8.3 Threshold 是业务选择

课堂用 banking / security 举例：若 false acceptance 代价很高，会选择更严格 threshold。AUC 高表示整体排序好，不替代具体 operating threshold 的代价分析。

8.4 Source Coverage Audit / 逐页覆盖核对

PDF 页码	已覆盖内容	笔记位置
4	本讲目标与三条主线	§1–§2
5–25	TER、shifted one-arm quadratic、闭式解、Example 5.4	§2–§4
26–36	AUC/AAC、pairwise differences、Example 5.5	§5
37–48	transformed analytic learning、TAUC 与统一框架	§6

PDF 页码	已覆盖内容	笔记位置
49–55	与 Bayesian inference 的联系	§7
56	分类 analytic solutions 关系总表	§10–§11
57	全讲总结	§12–§14

✓ **Coverage conclusion**

Lecture 6 的 substantive slides、Examples 5.4–5.5 与跨录音课堂补充均已纳入；长推导按课堂要求压缩为概念、shape 与最终式。

---

9. All Slide Exercises / Questions / PPT 中出现的例题与课堂练习汇总

题目	简明答案	正文位置
为什么 sigmoid 仍不理想?	nonlinear local solutions + saturation plateaus	3.1 Sigmoid approximation 的局限
为什么 quadratic 需要 offset?	让 relevant values 落在同一个 monotonic arm	3.3 Shifted one-arm quadratic
Example 5.4	third-order polynomial + TER，注意 one-hot threshold 为 0	4.5 Example 5.4 — TER classification
AUC pair counting	遍历 m^+m^- pairs，正确 1、tie 0.5、错误 0	5.1 为什么从 ROC 改成 AUC
为什么 $=+1$ 而非 -1 ?	在 normalized difference 区间内保持 wrong pair loss 更高	5.2 AUC 与 AAC
Example 5.5	由 pair differences 累积 closed form，再选 threshold	5.5 Example 5.5
TAUC → TER / FLD / LSE	通过 class scaling、translation、centering 与 weighting	6.2 TAUC 为什么能统一其他方法

---

10. 高频对比题总表

方法	优化对象	数据单位	Threshold	Class imbalance 处理
LSE	residual magnitude	single samples	训练式无；分类后加	默认按 samples 加权

方法	优化对象	数据单位	Threshold	Class imbalance 处理
TER	$FPR + FNR$	class-separated samples	显式 τ	每类除以 m，两类等权
AUC/AAC	pairwise ranking	positive-negative pairs	训练式无	每对等权；由 m^+m^- 归一化
FLD-like	within-class scatter 与 mean separation	centered class samples	后续决定	显式使用 class means
Weighted LS	weighted residual magnitude	weighted samples	后续决定	权重矩阵 M 决定

---

11. Exam-Focused Formula Sheet / 考试公式页

$$TER = FPR + FNR.$$

$$\hat{w}_{TER} = \left(bI + \frac{1}{m^-}P_-^T P_- + \frac{1}{m^+}P_+^T P_+\right)^{-1}\left(\frac{\tau -}{m^-}P_-^T \mathbf{1}_- + \frac{\tau +}{m^+}P_+^T \mathbf{1}_+\right).$$

$$AUC = \frac{1}{m^+m^-}\sum_{i=1}^{m^+}\sum_{j=1}^{m^-} u\Big(g(x_i^+) - g(x_j^-)\Big).$$

令 $d_{ij} = p_j^- - p_i^+$：

$$\hat{w}_{AAC} = \left[bI + \frac{1}{m^+m^-}\sum_{i,j} d_{ij}d_{ij}^T\right]^{-1}\left[-\frac{}{m^+m^-}\sum_{i,j} d_{ij}\right].$$

$$\tau_{TER} = \frac{1}{2m^-}\sum_j \hat{w}^T p_j^- + \frac{1}{2m^+}\sum_i \hat{w}^T p_i^+.$$

---

12. 一页速记 / One-Page Memory Map

```
Fixed operating point
FPR + FNR
    ↓ unify both errors to “> 0”
shift by η → use one quadratic arm
    ↓
TER closed form

All operating points
positive score − negative score
    ↓ count correctly ranked pairs
```

```
AUC ↑  ⇔  AAC ↓
    ↓ shifted pairwise quadratic
AUC/AAC closed form

Scaling + translation + centering
    ↓
AUC / TER / FLD / weighted LS / LSE relationships
```

---

13. Cornell Questions — 答案

Q1. 为什么 classification count 难优化?

因为 zero-one counting function 在 threshold 跳变、其他位置几乎处处 gradient 为 0，不能直接提供连续优化方向。

Q2. TER 为什么适合 class imbalance?

它分别用 m^- 与 m^+ 归一化 FPR 和 FNR，使两类在 objective 中等权，而不是让多数类凭样本数主导。

Q3. 两种 residual 怎样统一?

Negative 用 $\epsilon_j = g(x_j^-) - \tau$，positive 用 $_i = \tau - g(x_i^+) -$；两者大于 0 都代表误分类。

Q4. Sigmoid 的两个问题?

对参数仍是 nonlinear、可能有 local solutions；饱和区形成 plateaus，gradient 很小。

Q5. 为什么只用 quadratic 一个 arm?

完整 quadratic 两侧对称，不能区分正确与错误方向；offset 把 relevant residuals 放到同一个 monotonic side，才让 loss 顺序与 counting loss 一致。

Q6. TER closed form 的参数作用?

m 做 class normalization，τ 是 threshold， 是 quadratic offset，b 控制 weight decay，P 收集两类 transformed features。

Q7. AUC 与 AAC?

AUC 是正确排序 pair fraction；AAC 是错误排序 fraction。在相同 tie convention 下 maximize AUC 等价于 minimize AAC。

Q8. **为什么有** m^+m^- pairs?

每个 positive 都要与每个 negative 比较一次，因此 Cartesian product 的 pair count 是 m^+m^-。

Q9. AUC **训练后怎样选** threshold?

可用两类 mean scores 的中点作为 TER-optimal approximation，也可按应用的 false positive / false negative cost 调整。

Q10. Data transformation **怎样统一方法?**

Class-dependent scaling 决定保留哪些 class/pair terms，translation 可做 class-centering；特定设置分别退化为 AUC、TER、FLD-like 与 weighted LS / LSE。

Q11. TER **为什么像** weighted LS **与** dual-Gaussian regression?

其 quadratic surrogate 把两类拉向两个 constant targets，并按各自 class size / variance 加权，因此代数上是 weighted LS，概率上是两个 Gaussian residual groups。

Q12. **哪些要会计算?**

TER/AUC 的基础定义、class/pair normalization、核心 closed form 与简单 example 要会；generalized TAUC 的长推导主要理解 scaling、translation、centering 的关系，不要求死背。

---

14. 总结栏（Review）

Lecture 6 的关键创新不是换一个复杂公式，而是让分类目标与可闭式求解的 quadratic structure 相匹配。TER 在一个 threshold 上平衡两类错误；AUC 在所有 thresholds 上比较正负样本排序。两者都通过 offset 让 quadratic 只工作在单调的一侧。后半的 generalized framework 说明许多经典分类器的差别可被理解为对 data 的 weighting、scaling、translation 与 centering 不同。

一句话记忆

> **TER 看“两个类别各错多少”，AUC 看“每个正负样本对排得对不对”；两者都靠 shifted one-arm quadratic 获得闭式解。**