康奈尔学习笔记：Analytic Methods for Penalized Learning

惩罚学习、系数收缩与 Bridge Regression

日期 / Date： 2026-10-03
科目 / Subject： EE6406 Analytic and Ensemble Machine Learning
资料 / Sources： Lecture 7 课件（68 个 PDF pages）与课堂转录 `70764`。

> **本讲主线：** 只压低 training error 会过拟合 → 在 objective 中加入 coefficient penalty → L_2 得 ridge、L_1 得 lasso、一般 L_p 得 bridge → primal regularization 适合 over-determined，dual least-norm 适合 under-determined → 通过 coefficient profiles 检查 stability、compression 与 feature selection。

📚 学习导航与资料边界

学习目标	笔记位置	资料依据
理解 penalized learning 的目的与 bias-variance tradeoff	§2	6406/materials/EE6406-Lecture7-TKA-v1.pdf PDF pages 4–20
区分 ridge、lasso、bridge 与 least-norm	§3	课件 PDF pages 21–27
掌握 primal / dual ridge 的核心形式	§4	课件 PDF pages 28–34
理解 proximal bridge 的 primal / dual 结构	§5–§6	课件 PDF pages 35–44
解读 polynomial、prostate 与 XOR coefficient profiles	§7	课件 PDF pages 45–65
把握 CA2 计算与推导深度	§8	课堂转录
定位所有课件例题、图表与代码流程	§7、§9	Examples 6.1–6.2、Tables 1–4

前置： L5：Analytic Regression · L6：Advanced Analytic Classification
总索引： 6406/notes/EE6406_课程笔记索引.md

本笔记怎么读

阅读目标	建议顺序	读完应能回答
先理解为什么加 penalty	§2	training fit 为什么不能单独代表 generalization?

阅读目标	建议顺序	读完应能回答
区分三类 penalty	§3.1–§3.3	ridge、lasso、bridge 分别怎样改变 coefficients?
分清 primal 与 dual	§3.4 → §4	谁在 objective 中最小化 data error，谁在 exact-fit 解中选最小 norm?
看懂 bridge 更新	§5	为什么右侧仍有 w，因此需要迭代而不是一次求逆?
学会读实验图表	§7	coefficient profile、test MSE 与 selected variables 各说明什么?
考前复习	§10–§14	能说明 λ、p/k、shape 与 sparsity 的作用

> **本讲只抓一个权衡：** data-fit term 希望模型贴近训练数据，penalty 希望参数更小或更稀疏；λ 决定两种要求谁更重要，penalty 的形状决定“大家一起缩小”还是“把部分系数压成 0”。

线索栏（Cornell Questions）

1. Training error 继续下降时，test error 为什么可能上升?
2. Penalized objective 中 loss、penalty 与 λ 各负责什么?
3. Coefficient magnitude 为什么影响 stability 与 generalization?
4. Ridge、lasso 与 bridge 的 penalty 有何关系?
5. 为什么 L_1 容易产生 exact zeros，而 L_2 通常只 shrink?
6. Primal regularization 与 dual least-norm 的优化角色有何不同?
7. Primal / dual ridge 的 inverse 分别在哪个空间?
8. Ridge 的 λ 增大时，fit 与 coefficient norm 怎样变化?
9. Bridge 中 p 或 k 怎样控制 sparsity / compression?
10. Proximal bridge 为什么要用 smooth approximation $\sqrt{w_j^2+\epsilon}$?
11. Multiple outputs 怎样从单输出解堆叠得到?
12. Coefficient profile 图应该怎样读?

---

1. Knowledge Framework / 知识点框架

```
Empirical loss only
        ↓ model may fit noise
overfitting / unstable large coefficients
        ↓
penalized learning
min_w  data-fit loss + λ × coefficient penalty
        ├─ L2² → ridge / weight decay
        ├─ L1  → lasso / sparse selection
        └─ Lp^p → bridge family
```

```
System geometry
├─ over-determined → primal regularization
└─ under-determined → dual least-norm / dual bridge

λ path / coefficient profile
        ↓
compare fit, stability, compression and selected variables
```

参数	作用	增大时通常发生什么
λ	penalty 相对 data-fit loss 的权重	coefficients 更小、training fit 变差、variance 降低
p / k	penalty contour 的形状	越接近 1 越强调 sparse / compressive behavior
model order D	可表达的 feature terms 数	flexibility 增加，也提高 overfitting 与 conditioning 风险

---

2. Why Penalized Learning? / 为什么需要惩罚学习

2.1 只最小化 training error 的问题

高复杂度模型能追随 training noise，使 training error 持续下降，但 unseen-data error 在某一点后反而上升：

```
model complexity ↑
training error   ↓ monotonically
test error       ↓ then ↑
                     ↑
             optimal complexity
```

Penalization 不直接保证最优 generalization，但通过限制模型可用的 coefficient magnitude / complexity，减少过度拟合自由度。

训练误差与测试误差不是同一个目标

可以把模型复杂度从低到高分成三个阶段：

阶段	Training error	Test error	原因
太简单	高	高	连主要规律也表达不了，underfitting
适中	较低	最低附近	抓住主要规律，同时没有追随太多 noise
太复杂	很低甚至 0	重新升高	开始把 training noise 当规律，overfitting

Penalty 不直接看 test set，而是在 training objective 中限制模型自由度，降低进入第三阶段的风险。

2.2 通用形式

$$\boxed{\hat{w} = \underset{w}{\operatorname{argmin}} \left[\sum_{i=1}^{m} L(g(x_i, w), y_i) + \lambda R(w) \right].}$$

- L：要求模型解释 training data；
- $R(w)$：惩罚过大、过多或不符合先验结构的 coefficients；
- λ：控制 fit 与 simplicity 的权衡。

λ 状态	Objective 更在意什么	常见结果
$\lambda = 0$	只在意 training fit	回到 unregularized solution
较小	fit 为主，轻度限制参数	coefficients 略缩小
较大	penalty 更重要	coefficients 明显缩小，可能 underfit
$\lambda \to \infty$	几乎只想让参数最小	非截距参数趋近 0，模型失去表达能力

2.3 为什么 large coefficients 可能不稳定

对 $g(x, w) = w^T p(x)$，输入 perturbation p 引起：

$$g = w^T p.$$

若 $\|w\|$ 很大，即使 p 很小，输出也可能大幅变化。Coefficient shrinkage 因此既是 complexity control，也是 numerical / prediction stability control。

2.4 三类应用

1. **Penalized linear regression：** ridge、lasso；

2. **Feature selection：** high-dimensional genomics、text、finance 中用 sparsity 保留少数 variables；
3. **Neural networks / inverse problems：** weight decay 防过拟合，penalty 引入 stability 或 prior knowledge。

---

3. Coefficient Shrinkage / 系数收缩

3.1 Ridge：L_2^2 penalty

课程用 half scaling 写：

$$J_{SSEr}(w) = \frac{1}{2}\sum_{i=1}^{m}(y_i - p_i^T w)^2 + \frac{\lambda}{2}\|w\|_2^2.$$

它等价于在 SSE minimization 中加入约束 $\|w\|_2^2 \le t$。L_2 的圆形 / 球形 contour 平滑，通常同时缩小全部 coefficients，但不强迫许多元素恰好为 0。

3.2 LASSO：L_1 penalty

LASSO（Least Absolute Shrinkage and Selection Operator）：

$$\boxed{J_{lasso}(w) = \sum_{i=1}^{m}(y_i - p_i^T w)^2 + \lambda\|w\|_1,}$$

其中：

$$\|w\|_1 = \sum_{j=0}^{D}|w_j|.$$

它等价于约束 $\|w\|_1 \le c$。L_1 constraint 有尖角；loss contour 与尖角相切时，某些 coordinates 正好为 0，所以可做 embedded feature selection。

“尖角”可以这样理解：在 $w_j = 0$ 附近，$|w_j|$ 的斜率会从 -1 突然变成 $+1$。优化时，只要 data-fit term 提供的改善不足以克服这段 penalty，最优点就可以停在 $w_j = 0$。相比之下，w_j^2 在 0 附近的斜率连续趋近 0，更常把系数缩得很小，而不是恰好压成 0。

3.3 Bridge regression：一般 L_p^p penalty

$$\|w\|_p = \left(\sum_{j=0}^{D} |w_j|^p \right)^{1/p},$$

$$\boxed{SSE_{bridge}(w) = \sum_{i=1}^{m} (y_i - p_i^T w)^2 + \lambda \|w\|_p^p.}$$

课件关注 $0 \le p < 2$：

p 范围	典型效果	优化性质
$p = 2$	ridge-like smooth shrinkage	convex、smooth
$p = 1$	lasso-like sparsity	convex、在 0 不可导
$0 < p < 1$	更强 subset selection / compression	non-convex，优化更困难
$1 < p < 2$	compression 为主	smooth，通常较少 exact zeros

这里的 p（课件后文也写作 k）控制 penalty 的形状，不是 polynomial order。读公式时必须根据所在章节判断符号含义。

3.4 Regularization vs least-norm

两种写法容易混淆：

Approach	主 objective	Constraint / secondary term	常见系统
Primal regularization	data-fit loss	限制 / 惩罚 $\|w\|$	over-determined
Dual least-norm	$\|w\|$	exact fit $y = Pw$	under-determined

Least-norm L_2 problem：

$$\min_w \|w\|_2^2 \quad \text{s.t.} \quad y = Pw$$

给出：

$$\hat{w} = P^T (PP^T)^{-1} y$$

（要求 PP^T nonsingular）。一般化到 L_p 后，每个 sample constraint 对应一个 Lagrange multiplier。

---

4. Ridge Regression Revisited / 岭回归的 primal 与 dual

4.1 两个核心解

$$\boxed{\hat{w}_{primal} = (P^T P + \lambda I)^{-1} P^T y, \qquad \lambda > 0.}$$

$$\boxed{\hat{w}_{dual} = P^T (P P^T + \lambda I)^{-1} y, \qquad \lambda > 0.}$$

Primal inverse 的 size 是 $(D+1) \times (D+1)$；dual inverse 是 $m \times m$。这也是选择 computational form 的直接依据。

两式不是“超定只能用 primal、欠定只能用 dual”的绝对规则。更准确的判断是：比较 feature dimension $D+1$ 与 sample size m，并检查 rank 与 numerical conditioning；通常选择较小且更稳定的 inverse space。

4.2 Constrained view

Primal ridge 可写成：

$$\min_{w} \|y - Pw\|_2^2 \quad \text{s.t.} \quad \|w\|_2^2 \le c.$$

Dual least-norm 起点则是：

$$\min_{w} \|w\|_2^2 \quad \text{s.t.} \quad y = Pw.$$

对后一式写 Lagrangian 并对 w 求导，得到 $w = P^T \alpha$；再在 α space 加 regularization，得到 $(PP^T + \lambda I)^{-1}$。

4.3 Softening exact-fit constraint

若 exact fit $y = Pw$ 太严格，引入 residual ϵ：

$$\min_{w,\epsilon} \|w\|_2^2 + \gamma \|\epsilon\|_2^2 \quad \text{s.t.} \quad y = Pw + \epsilon.$$

课件推导出：

$$\lambda = \frac{1}{\gamma}, \qquad \hat{w} = P^T (P P^T + \lambda I)^{-1} y.$$

γ 大表示 residual 更昂贵，对应 λ 小；反之更强调小 coefficients。

4.4 Ridge 能做什么、不能做什么

- 能 shrink coefficients、改善 near-singular inverse 的 conditioning；
- 能降低 variance，但会引入 bias；
- 通常不会做 hard feature selection，因为 coefficients 很少精确等于 0；
- λ 应由 validation / cross-validation 选择，不能只看 training error。

---

5. Proximal Bridge Regression / 近端 Bridge 回归

5.1 为什么平滑 absolute value

$|w_j|$ 在 0 不可导。课件用：

$$f(w_j) = \sqrt{w_j^2 + \epsilon}, \qquad \epsilon > 0 \text{ small},$$

并定义 smooth k-measure：

$$|||w|||_k = \left(\sum_j f(w_j)^k \right)^{1/k}.$$

当 $\epsilon \to 0$ 时 $f(w_j) \to |w_j|$。课件特别说明：这个 smooth operator 不严格构成 normed vector space，因为它违反 absolute homogeneity；因此称 k**-measure**，不能无条件叫 L_k norm。

5.2 Primal p-bridge

对 over-determined system：

$$J(w) = (y - Pw)^T (y - Pw) + \lambda |||w|||_k^k.$$

课件给出 coefficient-dependent diagonal weighting form：

$$\boxed{\hat{w} = \left[\frac{\lambda k}{2} \text{diag}\left(|w|^{\circ(k-2)} \right) + P^T P \right]^{-1} P^T y,}$$

要求 bracketed matrix nonsingular。$\circ$ 表示 element-wise operation。

直觉

当 $k < 2$ 时，小 coefficient 在 $|w_j|^{k-2}$ 中对应更大的 effective penalty weight，因此被更强地压向 0；large coefficients 相对保留。

这不是一次代入即可得到的普通 closed form

右侧 diagonal matrix 仍含未知的 w，所以该式是 **implicit fixed-point equation**。实际求解常采用 iterative reweighted ridge：

1. 先给一个初值 $w^{(0)}$，通常可取 ridge solution；
2. 用当前 $w^{(t)}$ 计算每个 coefficient 的 effective penalty weight；
3. 固定这些 weights，解一次 weighted ridge 得到 $w^{(t+1)}$；
4. 重复直到 coefficients 或 objective 的变化足够小。

用平滑形式时，第 j 个 weight 可理解为与

$$\left((w_j^{(t)})^2 + \epsilon\right)^{\frac{k}{2}-1}$$

成正比。$k < 2$ 时指数为负，小 $|w_j|$ 产生更大权重，下一轮被压得更强。

读这个公式的顺序： P^TP 提供 data-fit curvature；diagonal term 为每个 coefficient 提供不同强度的 penalty；inverse 解出下一轮 parameters。不要把含 w 的 diagonal term 当作已知常数。

5.3 Dual p-bridge

对 under-determined system：

$$\min_w \|\|w\|\|_k^k \quad \text{s.t.} \quad y = Pw, \qquad 1 < k \leq 2.$$

课件最终解写为：

$$\hat{w} = \text{sgn}(\theta) \circ P^T(PP^T)^{-1} P\theta^{\circ(k-1)^{\circ\frac{1}{k-1}}},$$

其中：

$$\theta = |P^T|^{\circ\frac{1}{k-1}} \left[P|P^T|^{\circ\frac{1}{k-1}}\right]^{-1} y.$$

课堂边界： Bridge regression 要理解为什么需要、k 如何控制 compression / selection、primal 与 dual 各适合什么 shape，以及会直接应用最终式。老师明确说不要求从头背诵整段推导。

6. Multiple Outputs / 多输出扩展

若 C 个 outputs 条件独立并共享同一个 regressor matrix P，分别估计：

$$\hat{W} = [\hat{w}_1, \ldots, \hat{w}_C] \in \mathbb{R}^{(D+1)\times C}.$$

Prediction 仍是：

$$\hat{G} = P\hat{W}.$$

这与 L5 的 multi-category stacking 相同：算法对每个 target column 求一个 coefficient vector，再横向堆叠。若 outputs 之间存在结构依赖，简单独立堆叠则没有利用这种依赖。

---

7. Coefficient Profiles and Examples / 系数路径与例题

7.1 怎样读 coefficient profile

Coefficient profile 以 regularization strength（或其 path index）为横轴、各 w_j 为纵轴：

- 曲线快速靠近 0：该 variable 易被 penalty 抑制；
- 长时间保持较大 magnitude：该 term 对 fit 更重要或与其他 terms 共同承担解释；
- 精确落到 0：表示该 method 做了 variable selection；
- correlated variables 的系数路径可能互相替代，不能把 magnitude 直接当因果重要性。

建议按以下顺序读图：

1. 先确认横轴是 λ、$\log\lambda$ 还是 path index，以及从左到右 penalty 是增强还是减弱；
2. 看 $\lambda \approx 0$ 时是否接近 unregularized coefficients；
3. 找哪些 curves 最先到 0、哪些长期保留；
4. 再对照 validation / test error 选择 operating point，不能只追求“留下的变量最少”；
5. 最后检查 correlated variables 是否发生替代，避免把一次 path 当成稳定因果结论。

7.2 Example 6.1 — 十阶多项式恢复二、三次项

Training inputs：

$$x \in \{-5, -4, -3, -2, 0, 1, 2, 3, 4, 5, 6, 7, 8, 8.5, 9, 10\},$$

targets 由：

$$y = 10x^2 - x^3$$

生成。模型却使用含 intercept 的 tenth-order polynomial，共 11 个 coefficients：

$$[1, x, x^2, \ldots, x^{10}].$$

课件用 $\lambda = 1$、$k = 1.1$ 的 p-bridge。结果主要保留 x^2 与 x^3 对应 coefficients，其余高阶 terms 被压缩，说明 penalty 可从过度丰富的 basis 中恢复较简结构。

课件代码逻辑

```
construct P = [1, x, x², …, x¹⁰]
construct dense test grid P_t
solve p-bridge(P, y, k=1.1, λ=1, primal=True)
predict y_t = P_t w
plot training samples and prediction curve
```

7.3 Prostate example — over-determined coefficient profiles

数据有 67 training samples、30 test samples、8 inputs 加 intercept，共 9 coefficients，属于 over-determined linear regression。

Method	Tuned parameter(s)	Test MSE	Selected variables（不含 intercept）
OLS	-	0.520 (0.174)	All
Ridge	$\lambda = 1$	0.516 (0.175)	All
Lasso	$\lambda = 0.02$	0.483 (0.160)	1,2,3,4,5,6,8
Elastic-net	$\lambda = 0.06, \alpha = 0.11$	0.492 (0.164)	1,2,3,4,5,6,8
p-bridge, $k = 1$	$\lambda = 2$	0.494 (0.167)	1,2,3,4,5,6,8

括号中的数值按课件表格保留；课件将 `gleason` coefficient 压到 0，而 `lcavol` 保持最大 magnitude。应把这理解为该 fitted model / split 下的结果，不是变量的普遍因果结论。

7.4 XOR example — under-determined sparse polynomial

四个 training samples：

$$(x_1, x_2) \in \{(0,1), (2,1), (1,0), (1,2)\}, \qquad y \in \{0, 0, 1, 1\}.$$

使用 third-order polynomial 的 10 terms，因此 $P : 4 \times 10$，属于 under-determined system。

Method	Setting	Test MSE	Selected term indices
OLS	-	0.513 (0.089)	All
Ridge	$\lambda = 6$	0.503 (0.047)	0,1,2,3,4,6,7,8,9
Lasso	$\alpha = 1, \lambda = 0.1$	0.225 (0.011)	0,6,7
p-bridge	$k = 1.05, \lambda = 30$	0.504 (0.040)	6,7
p-bridge baseline	$k = 2, \lambda = 0$	0.513 (0.089)	All

课件的 p-bridge 在 $k = 1.05$ 时只保留 indices 6、7，即 x_1^3, x_2^3；decision contour 仍能完成 XOR separation。此例展示的是 **under-determined + nonlinear basis + sparse coefficient selection** 的组合。

7.5 结果表不能单独证明某方法普遍更优

这些表只是在指定 split、basis 与 tuned settings 下的 empirical results。正确比较还需要相同 train/test protocol、同等 tuning budget 与重复试验；本讲用它们主要展示不同 penalty 产生的 coefficient profiles。

---

8. Lecture Additions / 课堂口头补充

8.1 CA2 范围

课堂说明 CA2 scope 为 Lectures 5–7，concept 比 calculation 更多；需要会课件中的 basic calculations，不要求书后复杂计算。

8.2 L7 的学习重点

- 必须掌握 penalization 的 **how and why**；
- 会区分 L_2 ridge、L_1 lasso 与一般 bridge；
- 会按 P shape 选择 primal / dual ridge，并检查 inverse dimension；
- Bridge 重点是概念、最终形式与 coefficient behavior，不要求完整推导；
- 课堂将 bridge 称为更重要的新内容，但仍强调应用与 interpretation 高于死背 derivation。

8.3 λ 不是“越大越好”

λ 变大使 penalty 更重要、coefficients 更小，但过大时会 underfit。选择应依赖 validation / cross-validation，而非只看 training cost 或 coefficient 是否足够小。

8.4 Source Coverage Audit / 逐页覆盖核对

PDF 页码	已覆盖内容	笔记位置
4–20	过拟合动机、penalized objective、正则化直觉	§1–§2
21–27	ridge、lasso、bridge shrinkage	§3
28–34	ridge primal/dual 与 least-norm 对照	§4
35–44	proximal bridge 与多输出扩展	§5–§6
45–50	Example 6.1	§7.2
51–55	Prostate 数据与 coefficient profiles	§7.3
56–65	XOR 数据、不同 q 的边界与路径	§7.4
66	全讲总结	§11–§14
67–68	结束页与参考文献	已核对，无需重复抄录

✓ **Coverage conclusion**

Lecture 7 的 substantive slides、Example 6.1、两组实验与课堂补充均已纳入；bridge 长推导按课堂要求保留动机、关键桥梁和最终更新式。

---

9. All Slide Exercises / Questions / PPT 中出现的例题与课堂练习汇总

题目 / 图表	需要回答什么	正文位置
Overfitting vs regularization curve	为什么 training error 与 test error 趋势不同?	2.1 只最小化 training error 的问题
L_1 vs L_2 geometry	为什么 L_1 更易产生 zero coefficients?	3.2 LASSO：L_1 penalty
Ridge constrained derivation	Primal 与 dual 各把什么放在 objective / constraint?	3.4 Regularization vs least-norm、4.2 Constrained view
Proximal bridge formulas	k、λ、element-wise powers 各有什么作用?	5. Proximal Bridge Regression / 近端 Bridge 回归
Example 6.1	十阶 basis 怎样恢复 x^2, x^3 主结构?	7.2 Example 6.1 — 十阶多项式恢复二、三次项

题目 / 图表	需要回答什么	正文位置
Prostate Tables 1–2	哪些方法做 selection，MSE 与 sparsity 如何权衡?	7.3 Prostate example — over-determined coefficient profiles
XOR Tables 3–4 / contours	欠定 sparse nonlinear model 如何选择 terms?	7.4 XOR example — under-determined sparse polynomial

10. 高频对比题总表

Method	Penalty	Sparse exact zeros?	典型优点	主要代价
OLS	无	否	unbiased fit under assumptions、简单	高 variance、ill-conditioning、overfitting
Ridge	$\lambda\|w\|_2^2$	通常否	stable、处理 correlated features	保留全部 variables、引入 bias
Lasso	$\lambda\|w\|_1$	是	feature selection、interpretable	correlated features 下选择可能不稳定
Bridge	$\lambda\|w\|_p^p$	取决于 p	连续控制 compression / selection	$p<1$ non-convex，求解与 tuning 更难
Elastic-net	L_1+L_2	是	兼顾 sparsity 与 grouped shrinkage	多一个 mixing parameter

11. Exam-Focused Formula Sheet / 考试公式页

$$\hat{w}=\underset{w}{\operatorname{argmin}}\left[\sum_i L(g(x_i,w),y_i)+\lambda R(w)\right].$$

$$\begin{aligned}J_{ridge}(w)&=\|y-Pw\|_2^2+\lambda\|w\|_2^2,\\ J_{lasso}(w)&=\|y-Pw\|_2^2+\lambda\|w\|_1,\\ J_{bridge}(w)&=\|y-Pw\|_2^2+\lambda\|w\|_p^p.\end{aligned}$$

$$\begin{aligned}\hat{w}_{primal\ ridge}&=(P^TP+\lambda I)^{-1}P^Ty,\\ \hat{w}_{dual\ ridge}&=P^T(PP^T+\lambda I)^{-1}y.\end{aligned}$$

$$f(w_j)=\sqrt{w_j^2+\epsilon},\qquad \|w\|_k=\left(\sum_j f(w_j)^k\right)^{1/k}.$$

12. 一页速记 / One-Page Memory Map

```
Too much flexibility
        ↓
training error low, test error high
        ↓
add λ × penalty
        ├─ L2²: shrink all → ridge
        ├─ L1 : corners → exact zeros → lasso
        └─ Lpᵖ: tune compression / selection → bridge

P shape decides computational view
        ├─ m > D+1 → primal
        └─ m < D+1 → dual

Trace coefficients as λ changes
        ↓
coefficient profile
        ↓
fit vs stability vs sparsity
```

---

13. Cornell Questions — 答案

Q1. Training error 降低时，test error 为什么会升高?

模型开始拟合 training-specific noise 与偶然波动，variance 上升；这些细节在 unseen data 中不重复，所以 generalization 变差。

Q2. Loss、penalty 与 λ 各负责什么?

Loss 衡量 data fit，penalty 限制 coefficient structure / complexity，λ 决定二者相对权重。

Q3. Coefficient magnitude 为什么影响 stability?

$g = w^T p$；large $||w||$ 会放大小 input perturbation 与 measurement noise。

Q4. Ridge、lasso、bridge 的关系?

它们共享 SSE + penalty 框架；ridge 用 L_2^2，lasso 用 L_1，bridge 用一般 L_p^p，前两者是 bridge family 的特殊形状。

Q5. 为什么 L_1 更容易 exact zeros?

L_1 constraint 在 coordinate axes 上有尖角，loss contour 容易在尖角首次相切；这些点正对应某些 coordinates 为 0。L_2 boundary 光滑，通常只连续 shrink。

Q6. Primal regularization 与 dual least-norm 的角色?

Primal 以 data fit 为主、norm 为 penalty / constraint；dual least-norm 以小 norm 为主，并要求 exact fit，适合欠定系统在无穷多解中选代表。

Q7. Primal / dual ridge 的 inverse 在哪里?

Primal 在 feature space 求逆 $(D+1)\times(D+1)$；dual 在 sample space 求逆 $m\times m$。

Q8. λ 增大时怎样变化?

Coefficient norm 通常下降，training residual 上升；适度可降 variance，过大会 underfit。

Q9. p/k 怎样控制 sparsity?

接近 2 时像 ridge，主要 smooth shrinkage；接近 1 时更强 compression 并可能产生 zeros；低于 1 时 selection 更强但 objective non-convex。

Q10. 为什么用 $\sqrt{w_j^2+\epsilon}$?

它在 0 附近平滑 absolute value，允许 differentiation；$\epsilon\to 0$ 时逼近 $|w_j|$，但 finite ϵ 下该 operator 不严格是 norm。由于更新权重仍依赖当前 w，实际采用 iterative reweighted 求解，而不是一次代入得到普通 closed form。

Q11. Multiple outputs 怎样扩展?

对共享 P 的每个 target column 分别估计 $\hat{w}_c$，再组成 $\hat{W}=[\hat{w}_1,\ldots,\hat{w}_C]$，prediction 为 $P\hat{W}$。

Q12. Coefficient profile 怎样读?

沿 λ path 观察每个 coefficient 何时缩小或变为 0，并结合 validation error 选择 setting；不能把单次 coefficient magnitude 直接解释为因果重要性。

---

14. 总结栏（Review）

Lecture 7 把“不要过度拟合”转化为可计算的 objective：data-fit term 要解释 observations，penalty term 要控制 coefficient magnitude 或数量。Ridge 偏向稳定与 grouped shrinkage，

lasso 偏向 sparse selection，bridge 用 penalty exponent 在两类行为之间扩展。Primal / dual 的区别仍来自 L5 的 shape logic；coefficient profiles 则把抽象 penalty 变成可观察的 regularization path。

一句话记忆

> **λ 决定“拟合数据”与“压缩参数”谁更重要，penalty 的形状决定参数只是变小，还是会真正变成 0。**