EE6406 Week 1–4 衔接复习

看完即可继续 Week 5–7

> **目标：** 用约 35–45 分钟找回前四周的主线。这里不重复所有课件细节，只保留 Week 5–7 会直接调用的概念、公式、矩阵 shape 和判断方法。

原笔记： Week 1 · Week 2 · Week 3 · Week 4
接下来： Week 5 · Week 6 · Week 7

先看这张总图

周次	回答的问题	留给后续的接口
Week 1	为什么研究 analytic learning?	希望在结构允许时直接求出参数，而不是反复迭代
Week 2	数据怎样安全地变成可计算输入?	preprocessing、shape、矩阵乘法、梯度、argmin
Week 3	模型怎样表示?	design matrix P、primal/dual、polynomial、kernel
Week 4	什么叫“学得好”?	SSE、TER、AUC、regularization
Week 5	怎样直接求 regression 参数?	对 Week 3 的模型最小化 Week 4 的 SSE
Week 6	怎样让 TER/AUC 也能解析求解?	用近似损失或数据变换得到 closed form
Week 7	怎样抑制过拟合并选择变量?	在 objective 中加入 ridge/lasso/bridge penalty

前四周的核心不是记四份清单，而是记住：data 经过 preprocessing 形成表示 P；模型用 P 产生 score；loss 定义错误；objective 决定最终解出的参数。

---

1. Week 1：课程究竟在研究什么

1.1 机器学习的最小定义

Mitchell 的 E–T–P：

- E：experience，模型接触的数据或反馈；
- T：task，例如 regression、classification、ranking；
- P：performance measure，例如 MSE、accuracy、TER、AUC。

如果系统从经验 E 中学习后，在任务 T 上的指标 P 改善，就称它发生了学习。

> **Note**
>
> 这里 E–T–P 中的 P 是 performance；后文 $P \in \mathbb{R}^{N\times M}$ 是 design matrix。它们只是碰巧使用同一个字母。

1.2 Analytic learning

普通 iterative learning 逐步更新参数；analytic learning 在模型、loss 和 regularization 具有合适结构时，直接得到参数的显式解：

$$\hat{w} = \operatorname*{argmin}_{w} J(w) \quad \Longrightarrow \quad \hat{w} = \text{data 的显式函数}.$$

优点是训练快、结果确定、较容易解释；限制是只有特定结构可闭式求解，矩阵求解仍可能昂贵或不稳定。

> **Important**
>
> Closed form 不等于零计算，也不等于真的在程序中显式计算 inverse。实际数值实现通常使用 QR、SVD 或 linear solve。

1.3 Ensemble learning

Ensemble learning 组合多个 base learners 的预测。有效 ensemble 通常同时需要：

- 每个 learner 具有一定准确性；
- learners 之间有差异，不总犯同一种错误；
- 用 voting、averaging 或 weighted combination 汇总输出。

它提高的是整体可靠性与泛化，但训练、存储和解释成本也会上升。Week 5–7 主要沿 analytic learning 主线展开；ensemble 是课程后半部分的另一条主线。

1.4 Week 1 对 Week 5–7 的意义

- Week 5 展示 least squares、ridge、kernel regression 的解析解；
- Week 6 设法把难优化的 classification/ranking 目标改造成可解析形式；
- Week 7 在解析框架中加入 penalty，平衡拟合与复杂度。

2. Week 2：数据与数学工具箱

2.1 完整 pipeline

```
raw data
  → split train / validation / test
  → fit preprocessing on training only
  → transform all sets with the same fitted parameters
  → feature representation
  → learning
  → score / prediction
  → decision and evaluation
```

最重要的规则是：

> ⚠ **Warning**
>
> 先 split，再只在 training set 上估计 mean、standard deviation、min/max、imputation 或 feature-selection 参数。Validation/test 只能使用已经拟合好的变换，否则产生 data leakage。

2.2 数据类型为何重要

类型	能表达什么	例子	不能随便做什么
Nominal	只区分类别	颜色、国家	不能把任意整数编码当连续距离
Ordinal	有顺序	评级、名次	相邻等级距离未必相等
Interval	差值有意义	摄氏温度	零点任意，倍数无意义
Ratio	差值和倍数均有意义	长度、质量	仍需注意单位和尺度

这会影响 encoding、distance、normalization 和最终模型是否有意义。

2.3 Distance 与 metric

真正的 metric 必须满足：

1. 非负性；
2. $d(x,y)=0$ 当且仅当 $x=y$；
3. 对称性；
4. 三角不等式。

Minkowski distance：

$$d_p(x,y)=\left(\sum_j |x_j-y_j|^p\right)^{1/p}.$$

只有 $p\geq 1$ 时它才是 norm-induced metric；$0<p<1$ 一般违反三角不等式。Nominal 常用 Hamming；ordinal/ranking 可按问题使用 Spearman、Kendall、Cayley 或 Ulam。选择 distance 必须尊重数据类型。

2.4 三种常见 scaling

$$x'=\frac{x-x_{\min}}{x_{\max}-x_{\min}} \qquad (\text{minmax})$$

$$x'=\frac{x-\mu}{\sigma} \qquad (\text{score})$$

$$\text{MA}=\text{median}_i|x_i-\text{median}(X)| \qquad (\text{robust})$$

- min–max 依赖极值，容易受 outlier 影响；
- z-score 依赖 mean/std；
- MAD 依赖 median，对 outlier 更稳健。

Week 5–7 的公式默认数据已经形成合理的 numerical representation；坏的编码或 leakage 不会被闭式解自动修复。

2.5 后续最需要的线性代数

若

$$P\in\mathbb{R}^{N\times M},\qquad w\in\mathbb{R}^M,\qquad y\in\mathbb{R}^N,$$

则

$$Pw\in\mathbb{R}^N.$$

含义：

- N：training samples 数；
- M：model parameters / explicit features 数；
- P 的一行：一个样本的 feature representation；
- P 的一列：一个 basis function / feature。

矩阵乘法只在内侧维度一致时成立：

$$(N \times M)(M \times 1) = N \times 1.$$

任何 Week 5–7 计算题，第一行先写所有矩阵 shape。Shape 不对，后面的 inverse、primal/dual 和预测式必然错。

2.6 Rank、inverse、gradient

- Square matrix A 只有在 $\det(A)\ 0$、满秩时才可逆；
- columns 线性相关会令 P^TP singular；
- rows 线性相关会令 PP^T singular；
- inverse 的存在取决于 rank，不只是矩阵看起来是否 square。

Week 5 推导 normal equation 会用到：

$$\nabla_w(w^TAw) = (A + A^T)w.$$

若 $A = A^T$：

$$\nabla_w(w^TAw) = 2Aw.$$

还要分清：

$$\min_w J(w)$$

返回最小值，而

$$\operatorname{argmin}_w J(w)$$

返回取得最小值的参数 w。

---

3. Week 3：模型、design matrix 与 primal/dual

3.1 对输入非线性，不代表对参数非线性

基础线性参数模型：

$$g(x, w) = w^T x.$$

加入 bias 后：

$$g(x, w) = w_0 + w^T x.$$

把输入先变换为 $p(x)$：

$$g(x, w) = w^T p(x).$$

即使 $p(x)$ 包含 x^2、$x_1 x_2$、$\sin x$，模型仍然对参数 w 线性，因此可以接 Week 5 的 least-squares closed form。

3.2 Design matrix

把每个样本的 feature row 堆叠：

$$P = \begin{bmatrix} p(x_1)^T \\ p(x_2)^T \\ \vdots \\ p(x_N)^T \end{bmatrix} \in \mathbb{R}^{N \times M}.$$

训练 score：

$$\hat{y} = Pw.$$

测试集若有 N_t 个样本：

$$P_t \in \mathbb{R}^{N_t \times M}, \qquad \hat{y}_t = P_t w.$$

P_t 必须使用和训练时完全相同的 feature 顺序与 preprocessing 参数。

Score、link 与 decision

Linear score $g(x) = w^T p(x)$ 可以直接用于 regression，也可以再经过 link：

$$\mathrm{r}(Y = 1 \mid x) = \sigma(g(x)) = \frac{1}{1 + e^{-g(x)}}.$$

最后还需要 threshold 才成为 hard class decision。Sigmoid 使输出落在 $(0,1)$，但相应训练通常不再具有普通 least squares 那样的直接闭式解；这也是 Week 6 研究 link–loss matching 的背景。

3.3 三类线性系统

类型	Shape	典型情形	Week 5 对应
Square	$N = M$	方程数等于参数数	可逆时直接求解
Over-determined	$N > M$	样本多于参数	primal least squares
Under-determined	$N < M$	参数多于样本	dual minimum-norm

在满秩条件下：

$$\hat{w} = (P^T P)^{-1} P^T y \qquad (N > M),$$
$$\hat{w} = P^T (P P^T)^{-1} y \qquad (N < M).$$

两式的关键不是死背左右，而是比较 inverse 大小：

- $P^T P$ 是 $M \times M$，在 parameter / feature space；
- $P P^T$ 是 $N \times N$，在 sample space。

3.4 Polynomial features

二维二阶 full polynomial：

$$p(x) = \begin{bmatrix} 1 & x_1 & x_2 & x_1^2 & x_1 x_2 & x_2^2 \end{bmatrix}^T,$$

所以 $M = 6$。d 个原始变量、总次数不超过 r 时，含 intercept 的 monomial 数：

$$M = \binom{d + r}{r}.$$

次数增大时 M 很快爆炸：

- 会改变 over/under-determined 状态；
- 可能引起 multicollinearity 与 numerical instability；
- 为 Week 7 的 regularization 与 sparsity 埋下动机。

Week 3 还介绍 reduced multivariate polynomial：不枚举 full polynomial 的所有 monomials，而是用受控结构降低参数数量。衔接 Week 5–7 时记住其动机即可。

3.5 Kernel 与 dual representation

把 primal parameter 写成：

$$w = P^T\alpha, \qquad \alpha \in \mathbb{R}^N.$$

代入预测：

$$Pw = PP^T\alpha = K\alpha,$$

其中 Gram matrix：

$$K = PP^T \in \mathbb{R}^{N\times N}.$$

一般 kernel 直接计算：

$$K_{ij} = k(x_i, x_j),$$

无需显式生成高维 $p(x)$。测试 kernel：

$$K_t \in \mathbb{R}^{N_t\times N}, \qquad \hat{y}_t = K_t\alpha.$$

常见 kernel：

$$k(x_i, x_j) = x_i^T x_j \qquad (\text{linear}),$$

$$k(x_i, x_j) = (a + b\, x_i^T x_j)^r \qquad (\text{polnomial}),$$

$$k(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right) \qquad (\text{aussian/RF}).$$

---

4. Week 4：loss、objective 与评价标准

4.1 五个部件

$$\hat{w} = \underset{w}{\operatorname{argmin}} \left[\sum_{i=1}^{N} L\big(g(x_i, w), y_i\big) + \lambda R(w)\right].$$

部件	回答的问题
Model g	参数怎样产生 score?
Loss L	单个样本怎样算错?
Regularization R	希望参数具有什么结构?
Objective J	训练时总体优化什么?
Solver	怎样找到 $\hat{w}$?

Week 3 主要给 model；Week 4 给 loss/objective；Week 5–7 才真正求解这些组合。

4.2 常见 loss 的任务分工

令 binary label $y \in \{-1, +1\}$，margin 为 $\mu = yg(x)$：

Loss	形式	作用
Squared	$(g-y)^2$	regression；易导出 closed form
0–1	$\mathbf{1}[\mu < 0]$	直接表达错分，但不可导
Hinge	$\max(0, 1-\mu)$	margin classification surrogate
Logistic	$\log(1+e^{-\mu})$	平滑 classification surrogate
Binary cross-entropy	$-y\log p-(1-y)\log(1-p)$	probability classification

核心原则：同一个 model 搭配不同 loss，会得到不同最优参数。Week 6 的重点正是为 TER/AUC 选择可解析的 surrogate 或 transformation。

4.3 Regression：SSE

$$J(w) = \|Pw - y\|_2^2 = (Pw-y)^T(Pw-y).$$

MSE 与 SSE 相差正数 N：

$$\operatorname*{argmin}_w \mathrm{MSE}(w) = \operatorname*{argmin}_w \mathrm{SSE}(w).$$

Week 5 将对这个 objective 求梯度并得到 over/under-determined closed form。

4.4 Classification：score 不等于 class

模型先输出 score $g(x)$，再由 threshold τ 得到类别：

$$\hat{c}(x) = \begin{cases} 1, & g(x) \geq \tau, \\ 0, & g(x) < \tau. \end{cases}$$

Threshold 改变时，FP 与 FN 的取舍也改变。必须统一 tie 的归属。

Ground truth \ Prediction	Positive	Negative
Positive	TP	FN
Negative	FP	TN

$$TPR = \frac{TP}{TP + FN}, \qquad FNR = \frac{FN}{TP + FN},$$
$$TNR = \frac{TN}{TN + FP}, \qquad FPR = \frac{FP}{TN + FP}.$$

因此：

$$TPR + FNR = 1, \qquad TNR + FPR = 1.$$

4.5 TER：两类各占相同权重

$$TER = FPR + FNR, \qquad HTER = \frac{FPR + FNR}{2}.$$

$$\text{alanced Accurac} = 1 - HTER.$$

普通 error rate 按所有样本平均，可能被多数类主导；TER 分别按正负类归一化，所以适合 class imbalance。

Week 6 会问：TER 本来由不可导的错误计数组成，怎样近似并得到 closed form?

4.6 AUC：看排序而非固定 threshold

对每个 positive–negative pair：

$$\xi_{ij} = g(x_i^+) - g(x_j^-).$$

$$AUC = \frac{1}{N^+ N^-} \sum_{i=1}^{N^+} \sum_{j=1}^{N^-} u\left(g(x_i^+) - g(x_j^-)\right).$$

因此 AUC 可理解为：随机抽一个 positive 和一个 negative，positive score 更高的概率，tie 通常计 0.5。

- Accuracy / TER 依赖特定 threshold；
- AUC 汇总整体 ranking；
- TER 要最小化，AUC 要最大化；
- 若统一写 minimization，可最小化 $1 - AUC$ 或 pairwise surrogate loss。

Week 6 会把每个正负样本对变成 difference sample，以解析方式优化 ranking。

两个相关指标：

$$EER: \quad FPR(\tau) = FNR(\tau),$$
$$Gini = 2AUC - 1.$$

EER 是某个 threshold 的 operating point；AUC/Gini 描述整体排序，不能混为一谈。

4.7 Regularization：Week 7 的入口

$$J(w) = \underbrace{\|Pw - y\|_2^2}_{\text{fit data}} + \lambda \underbrace{R(w)}_{\text{control complexit}}.$$

常见 penalty：

$$R_2(w) = \|w\|_2^2 \qquad (\text{ridge}),$$
$$R_1(w) = \|w\|_1 \qquad (\text{lasso}).$$

- $\lambda = 0$：只看 training fit；
- λ 增大：更偏好小参数，variance 通常下降、bias 通常上升；
- ridge 连续 shrink coefficients，通常不会产生精确零；
- lasso 的尖角使解更容易落在坐标轴上，产生 sparsity。

---

5. 一个例子串起 Week 2–7

假设输入 $x = (x_1, x_2)$，使用二阶 polynomial：

$$p(x) = \begin{bmatrix} 1 & x_1 & x_2 & x_1^2 & x_1x_2 & x_2^2 \end{bmatrix}^T.$$

所以 $M = 6$。

情形 A： $N = 10$

$$P \in \mathbb{R}^{10\times 6}.$$

$N > M$，是 over-determined：

$$\hat{w} = (P^T P)^{-1} P^T y.$$

这就是 Week 5 的 primal least squares。

情形 B：$N = 4$

$$P \in \mathbb{R}^{4\times 6}.$$

$N < M$，是 under-determined。方程可能有无穷多组 exact-fit parameters；minimum-norm 解为：

$$\hat{w} = P^T (P P^T)^{-1} y.$$

这就是 Week 5 的 dual / sample-space 解。

情形 C：矩阵 singular 或解不稳定

加入 ridge：

$$\hat{w}_\lambda = (P^T P + \lambda I)^{-1} P^T y.$$

Dual 形式：

$$\hat{w}_\lambda = P^T (P P^T + \lambda I)^{-1} y.$$

这是 Week 5 的 ridge，也是 Week 7 的 L_2 penalization。

情形 D：不想显式列出 polynomial features

令

$$K_{ij} = k(x_i, x_j),$$

用 kernel ridge：

$$\alpha = (K + \lambda I)^{-1} y, \qquad \hat{y}_t = K_t \alpha.$$

这是 Week 3 的 kernel 表示进入 Week 5 的解析解。

情形 E：目标是 classification

可先用 regression target 学 score，再 threshold / argmax 得到类别。但不同 objective 会强调不同事情：

- SSE：让 numerical residual 小；
- TER：让两类 normalized errors 小；
- AUC：让 positive 排在 negative 前面；
- penalty：让解更稳定或更 sparse。

这正是 Week 6–7 在 Week 5 之上增加的内容。

---

6. 开始 Week 5–7 前必须会的公式

主题	最低要求
Design matrix	$P : N \times M$，rows 是 samples，columns 是 features/parameters
Test matrix	$P_t : N_t \times M$
Over-determined LS	$(P^T P)^{-1} P^T y$
Under-determined minimum norm	$P^T (P P^T)^{-1} y$
Primal ridge	$(P^T P + \lambda I)^{-1} P^T y$
Dual ridge	$P^T (P P^T + \lambda I)^{-1} y$
Kernel matrices	$K : N \times N$，$K_t : N_t \times N$
Kernel ridge	$\alpha = (K + \lambda I)^{-1} y$，$\hat{y}_t = K_t \alpha$
SSE	$\|Pw - y\|_2^2$
TER / HTER	$FPR + FNR$；$(FPR + FNR)/2$
AUC	positive score 大于 negative score 的 pairwise 概率
Penalized objective	loss $+\lambda R(w)$

做题顺序：写 shape → 判断 task → 选择 objective → 判断 primal/dual → 检查 inverse/rank → 求参数 → 用 train-consistent representation 预测 → 再 threshold、argmax 或计算 metric。

6.1 高频概念速查

概念	一句话理解	关键公式 / 注意点
Mathematical metric	衡量两个对象距离的“合法尺子”	必须满足非负、同一、对称、三角不等式；$\|x - y\|_2^2$ 一般不是 metric

概念	一句话理解	关键公式 / 注意点
Evaluation metric	衡量模型表现的成绩单	Accuracy、MSE、TER、AUC 不要求满足距离的四条公理
Vector gradient	标量函数对向量的各分量求偏导后组成的向量	$df = (\nabla_w f)^T dw$；$\nabla_w (w^T A w) = (A + A^T)w$
Normal equation	对 least-squares objective 求梯度并令其为零	$\nabla_w \|Pw - y\|^2 = 2P^T(Pw - y) = 0 \;\; P^T P w = P^T y$
Polynomial feature count	d 个变量、总次数不超过 r 的 full polynomial 特征数	$M = \binom{d+r}{r}$，包含常数项；恰好 r 次则为 $\binom{d+r-1}{r}$
Closed form	参数能写成数据的有限显式公式，不需要迭代搜索	例如 $\hat{w} = (P^T P)^{-1} P^T y$；closed form 不代表零计算或应该显式求 inverse
SSE / MSE	总平方误差 / 平均平方误差	$SSE = \|Pw - y\|^2$，$MSE = SSE/N$；固定 N 时二者的 $\arg\min$ 相同
TER / HTER	两类错误率之和 / 平均值	$TER = FPR + FNR$，$HTER = (FPR + FNR)/2$，适合 class imbalance
EER	选择阈值 τ，使两类错误率相等	$FPR(\tau) = FNR(\tau) = EER$；此时 $HTER = EER$，$TER = 2EER$
Dual / kernel	用每个训练样本的系数表示模型，以样本间内积完成预测	$w = P^T \alpha$，$K = PP^T$，$K_{ij} = k(x_i, x_j)$，$g(x) = \sum_i \alpha_i k(x, x_i)$
Ridge	在拟合误差外惩罚大参数，使解更稳定	$\min_w \|Pw - y\|^2 + \lambda \|w\|^2$；$\hat{w}_\lambda = (P^T P + \lambda I_M)^{-1} P^T y = P^T (PP^T + \lambda I_N)^{-1} y$

> **Note**
>
> Ridge 中加入 λI 会把 $P^T P$ 的特征值从 σ_i^2 提升为 $\sigma_i^2 + \lambda$。当 $\lambda > 0$ 时可避免 singular，并改善接近奇异时的数值稳定性；$M < N$ 通常用 primal，$N < M$ 或使用 kernel 时通常用 dual。

---

7. Readiness Check / 衔接自测

先遮住答案，口头回答即可。

1. $P \in \mathbb{R}^{12 \times 5}$ 是 over- 还是 under-determined？应优先在多大的空间求 inverse？
2. $P \in \mathbb{R}^{4 \times 20}$ 时，为什么 $(P^T P)^{-1}$ 通常不能用？
3. 模型含 x^2 时，为什么仍可能是 linear-in-parameter model？
4. $P^T P$ 与 PP^T 的 shape 分别是什么？

5. $w = P^T \alpha$ 中 w 与 α 的维度分别由什么决定?
6. 为什么 kernel trick 能避开显式高维 feature map?
7. Score $g(x) = 0.8$ 是否自动等于 positive class?
8. TER 为什么比 raw error rate 更适合不平衡类别?
9. AUC 与 accuracy 最大的差别是什么?
10. λ 增大通常如何影响 fitting 与 complexity?
11. 为什么 preprocessing 参数不能由整个 dataset 计算?
12. Week 5、6、7 分别在前四周基础上新增什么?

▶ 答案

---

8. 接下来怎样读 Week 5–7

Week 5：先建立求解骨架

阅读顺序：

1. §2：SSE 与 design matrix；
2. §3–§4：over/under-determined；
3. §5：ridge 的 primal/dual；
4. §6：kernel regression；
5. §7：从 score 到 classification。

阅读时反复问：inverse 是 $M \times M$ 还是 $N \times N$?

Week 6：先分清 TER 与 AUC

- TER：固定 threshold 下，两类错误分别归一化；
- AUC：不固定 threshold，比较所有正负样本对；
- 重点是如何把 counting/ranking objective 变换为 quadratic analytic problem；
- 长参数表先理解 transformation 思想，不必一开始死背。

Week 7：先抓 penalty 的行为

- Ridge：稳定、连续 shrink；
- Lasso：容易产生 exact zeros；
- Bridge：用一般 p 控制 compression 与 selection；
- 先理解 λ 与 p 的作用，再读 proximal 推导。

✓ Success

如果你能独立完成 §7 的 12 题，就不需要重新逐页学习 Week 1–4，可以直接进入 Week 5。遇到具体缺口时，再回到对应分讲笔记查细节。

总结栏

Week 1–4 建立了后续解析学习的四层地基：

1. **Why：** 在结构允许时直接求参数；
2. **Data：** 安全预处理并保持 train/test 一致；
3. **Model：** 用 P、polynomial 或 kernel 表示输入；
4. **Objective：** 用 SSE、TER、AUC 与 regularization 定义“好解”。

Week 5–7 只是在这四层之上继续回答：

$$\boxed{\text{怎样求解} \;\rightarrow\; \text{怎样处理 classification/ranking} \;\rightarrow\; \text{怎样控制复杂度}}$$