EE6407 Quiz 2 Review — Slides 6–10

Genetic Algorithms and Machine Learning · Mao Kezhi 部分

Quiz 2: 2026-11-10（周二）9:30–10:30；**40 minutes**；考场见 `6407/quiz2/Quiz2Venue.pdf`。

Coverage: **Classification Tree / Classifier Performance Evaluation / Regression / Feature Selection / K-means Clustering**（Slides 6–10）。

Language: 英文考试；本资料用中文讲解，但所有**专业术语保留英文**，并给出英文答题句式。

Sources: `6407/week10/ML-Slides6.pdf`、`week11/ML-Slides7.pdf`、`week11/ML-Slides8.pdf`、`week12/ML-Slides9.pdf`、`week12/ML-Slides10.pdf`、`week12/week12.txt`、`6407/Learning_note.md`（Week 10–12）。

---

0. 40 分钟考试策略

项目	建议
题量	5 个 topic，预计 4–6 题（含 1–2 道计算）
时间	每题约 7–8 分钟；计算题先写公式再代数字
语言	用英文答题；关键术语不要翻译成中文
计算器	按课程通知；简单计算尽量手算
检查	单位、符号（Gini vs entropy 不可比）、分母（precision vs recall）

英文答题常用句式:

- "The Gini impurity of the node is …"
- "The impurity drop is …; therefore the best split is …"
- "Accuracy = (TP+TN)/N = …"
- "Precision = TP/(TP+FP) = …; Recall = TP/(TP+FN) = …"
- "The OLS estimate is $\theta = (F^T F)^{-1} F^T y$."
- "K-means minimizes the within-cluster sum of squares (WCSS)."

---

1. Classification Tree（分类树）— Slide 6

1.1 Key terms（必背英文）

English term	中文	一句话
root node	根节点	第一个问题
internal node	内部节点	中间问题
leaf node	叶节点	输出 class label
branch	分支	问题的答案
split	分裂	用 feature + threshold 分数据
impurity	不纯度	节点混合程度；越小越纯
entropy impurity	熵不纯度	`-Σ p log2 p`
Gini impurity	Gini 不纯度	`1 - Σ p²`（或 `1/2[...]`）
misclassification impurity	误分类不纯度	`1 - max p`
variance impurity	方差不纯度	`p1 p2`（二分类）
impurity drop	不纯度下降	选 split 的准则
gain ratio	增益率	multi-split 的修正
continuous feature	连续特征	排序 + 中点作为候选 split
stopping criterion	停止准则	何时停止长树
pruning	剪枝	合并相邻 leaf，防过拟合
leaf label	叶节点标签	多数类
random forest	随机森林	bagging + random feature subset

1.2 Why classification tree?

- **Nonmetric method**：不依赖 Euclidean distance，能处理 **nominal / categorical / mixed data**；
- **Interpretable**：树 = if-then rules；
- **Handles nonlinearity and feature interactions**；
- 缺点：单棵深树 **high variance**，容易 overfit → 需要 stopping/pruning，或 random forest。

1.3 Impurity measures（公式 + 原理）

设节点 N 中第 j 类比例为 `p_j`。

Entropy impurity：

```
i_E(N) = - Σ_j p_j log2(p_j)
```

- 纯节点（只有一类）→ 0；

- 二分类 50/50 → 1；
- 熵越大 → 越混合。

Gini impurity：

```
i_Gini(N) = Σ_{j≠k} p_j p_k = (1/2)[1 - Σ_j p_j²]
```

- 纯节点 → 0；
- 二分类 50/50 → 0.5；
- 二分类可写 `2p(1-p)`。

Variance impurity（二分类）：

```
i_Var(N) = p1 * p2
```

Misclassification impurity：

```
i_MC(N) = 1 - max_j p_j
```

⭐ **四种 measure 的数值不能直接比较**；同一棵树/同一题只用一种 measure。

1.4 Split selection（impurity drop）

```
Δi(N) = i(N) - P_L i(N_L) - P_R i(N_R)
```

- `P_L = n_L/n`，`P_R = n_R/n`；
- **maximize Δi ⇔ minimize weighted child impurity**；
- multi-split：`Δi = i(N) - Σ_k P_k i(N_k)`；
- multi-split 偏爱大 B → 用 **gain ratio**：

```
Δi'(N) = Δi(N) / ( - Σ_k P_k log2 P_k )
```

1.5 Worked example 1：Gini vs Entropy（10 个样本）

父节点：10 个样本，正负各 5。

```
G_parent = 1 - 0.5² - 0.5² = 0.5
H_parent = -0.5 log2 0.5 - 0.5 log2 0.5 = 1 bit
```

分裂后：

- 左：5 个，4 正 1 负；
- 右：5 个，1 正 4 负。

```
G_L = 1 - 0.8² - 0.2² = 0.32
G_R = 0.32
G_after = 0.5*0.32 + 0.5*0.32 = 0.32
ΔG = 0.5 - 0.32 = 0.18
```

```
H_L = -0.8 log2 0.8 - 0.2 log2 0.2 ≈ 0.7219
H_R ≈ 0.7219
H_after ≈ 0.7219
ΔH = 1 - 0.7219 = 0.2781 bit
```

⭐ 两个指标都说明 split 变纯，但 **0.18 和 0.2781 不能直接比大小**。

1.6 Worked example 2：Heart disease（连续 + 离散）

303 个样本；Class 1 = 139（with heart attack），Class 2 = 164（without）。

Candidate `sex`（Sex=0?）：

- 左：25 / 72（97 个）；
- 右：114 / 92（206 个）。

```
G_left = 0.1913
G_right = 0.2471
G_sex = (97/303)*0.1913 + (206/303)*0.2471 ≈ 0.2276
```

（按公式精确复算约 0.2293；课件写 0.2276，以方法为准。）

Candidate `fbs`（fbs=0?）：

- 左：117 / 141（258）；
- 右：22 / 23（45）。

```
G_left = 0.2478
G_right = 0.2499
G_fbs = (258/303)*0.2478 + (45/303)*0.2499 ≈ 0.2481
```

Candidate `age`（continuous）：

1. 排序：29, 34, 35, 37, ...
2. 相邻中点：31.5, 34.5, 36, ...
3. 逐个试，选 impurity 最小的 split point。

以 `age > 31.5` 为例：

- 左：139 / 163（302）；
- 右：0 / 1（1）。

```
G_left = 0.2484
G_right = 0
G_31.5 = (302/303)*0.2484 + (1/303)*0 ≈ 0.2476
```

`age` 的最低 Gini 是 **0.228 @ 54.5**。

⭐ 比较所有 feature：假设 `sex` 最低 → root node = `Sex = 0?`；左分支继续用 `exang`（0.1493）而不是 `fbs`（0.1831）。

1.7 Stopping / Pruning / Leaf label

Stopping criteria：

- maximum depth；
- minimum samples to split；
- minimum samples per leaf；
- minimum impurity decrease；
- cross-validation / validation error；
- trade-off `J = α*size + Σ_leaf i(N)`。

Pruning：

- 合并相邻 leaf pair（same parent）；
- 若 impurity 上升可接受 → merge，parent becomes leaf；
- pruning = inverse of splitting。

Leaf label：

- 纯 leaf → that class；
- 不纯 → **majority class**（most samples）。

1.8 Random Forest（Slide 6 末尾）

- **Bagging**：bootstrap sampling（with replacement）+ train one tree per sample；
- **Random feature subset**：每次 split 只从 `m` 个随机 feature 中选（classification 常用 `√p`，regression 常用 `p/3`）；
- **Prediction**：classification majority vote；regression average；
- **Why**：降低树间 correlation → 平均后 variance 更低；
- **OOB**：约 36.8% 样本未进入某 bootstrap，可做 out-of-bag estimate。

1.9 Exam traps

Trap	Correct
Gini 和 entropy 数值可直接比	❌ 刻度不同
Gini 的 `1/2` 必须保留	❌ 缩放因子，不影响 split 排序
树越深越好	❌ 深树 high variance，overfit
连续 feature 不能用于树	❌ 排序 + 中点做候选 split
RF 只随机选样本	❌ 还随机选 feature
Leaf label 用平均	❌ classification 用 majority

---

2. Classifier Performance Evaluation（分类器性能评估）— Slide 7

2.1 Key terms

English term	中文
holdout method	留出法
repeated holdout	重复留出
k-fold cross-validation	K 折交叉验证
leave-one-out (LOOCV)	留一法
repeated k-fold	重复 K 折
stratified sampling	分层采样
confusion matrix	混淆矩阵
TP / FP / TN / FN	真阳/假阳/真阴/假阴
accuracy / error rate	准确率/错误率
sensitivity / specificity	敏感度/特异度
precision / recall	精确率/召回率
F1 score	F1 分数
ROC curve / AUC	ROC 曲线/曲线下面积
threshold	阈值

2.2 Evaluation procedures（步骤）

Method	Procedure	Notes
Holdout	random split: 70–80% train, 20–30% test	simple; one random split
Repeated holdout	repeat holdout many times; average performance	reduces randomness
K-fold CV	split into K folds; each fold used once as test; average K results	K=5/10 common
LOOCV	K=N; one sample as test each time	expensive; small data
Repeated K-fold	repeat K-fold multiple times with reshuffling	reduces variance
Stratified sampling	sample each class separately to preserve class ratio	for class imbalance

⭐ **Validation vs Test**：validation 用来调 hyperparameter / early stopping；test 只在最后用一次。

2.3 Confusion matrix + metrics（worked example）

Example（N=100）:

	Actual Positive	Actual Negative
Predicted Positive	TP = 85	FP = 4
Predicted Negative	FN = 2	TN = 9

Accuracy：

```
Accuracy = (TP + TN) / N = (85 + 9) / 100 = 94%
```

Error rate：

```
Error rate = (FP + FN) / N = (4 + 2) / 100 = 6%
```

Sensitivity / Recall：

```
Sensitivity = TP / (TP + FN) = 85 / 87 ≈ 97.7%
```

Specificity：

```
Specificity = TN / (TN + FP) = 9 / 13 ≈ 69.2%
```

Precision：

```
Precision = TP / (TP + FP) = 85 / 89 ≈ 95.5%
```

F1：

```
F1 = 2 * Precision * Recall / (Precision + Recall)
   = 2 * 0.955 * 0.977 / (0.955 + 0.977)
   ≈ 0.966
```

⭐ 记忆：

- **Precision 分母 = predicted positive（TP+FP）**；
- **Recall 分母 = actual positive（TP+FN）**；
- **Recall = Sensitivity**；
- F1 = precision 和 recall 的 harmonic mean。

2.4 ROC curve and AUC

- 默认 threshold = 0.5；改变 threshold 会改变 TP/FP/TN/FN；
- **TPR = TP/(TP+FN) = Sensitivity = Recall**；
- **FPR = FP/(FP+TN) = 1 - Specificity**；
- ROC：横轴 FPR，纵轴 TPR；每个 threshold 一个点；
- **AUC**：ROC 下面积；
- 1 = perfect；
- 0.5 = random；

- 0 = completely reversed；
- higher is better。

⭐ AUC 是 **threshold-independent** 的总体区分能力。

2.5 Exam traps

Trap	Correct
Accuracy 高就一定好	❌ class imbalance 时 misleading
Precision = Recall	❌ 分母不同
Sensitivity = Specificity	❌ positive vs negative class
ROC 的横轴是 TPR	❌ 横轴 FPR，纵轴 TPR
AUC=0.5 最好	❌ 0.5 是 random
Test set 可以用来调参	❌ 会泄漏，变成 validation

3. Regression（回归）— Slide 8

3.1 Key terms

English term	中文
simple linear regression	简单线性回归
multiple linear regression	多元线性回归
predictor / independent variable	自变量
target / dependent variable	因变量
residual / error	残差/误差
ordinary least squares (OLS)	普通最小二乘
design matrix F	设计矩阵
normal equation	正规方程
ridge regression	岭回归（L2）
lasso regression	Lasso（L1）
MSE / RMSE / MAE	均方误差/均方根/平均绝对误差
R^2 / adjusted R^2	决定系数/调整决定系数

3.2 Model

Simple linear regression：

```
y = θ0 + θ1 x + ε
```

- θ0：intercept（截距）；
- θ1：slope（斜率）；
- ε：residual / noise。

Multiple linear regression：

```
y = θ0 + θ1 x1 + θ2 x2 + ... + θm xm + ε
```

Vector form（with `x0 = 1`）：

```
y = θᵀ x + ε
```

3.3 OLS（normal equation）

Given N samples, design matrix `F` （each row = `[1, x1, ..., xm]`），target vector `y`：

```
y = F θ + ε
```

Loss（sum of squared residuals）：

```
J(θ) = (y - Fθ)ᵀ (y - Fθ)
```

Derivative：

```
∂J/∂θ = -2 Fᵀ(y - Fθ) = 0
```

Normal equation：

```
θ_hat = (Fᵀ F)⁻¹ Fᵀ y
```

⭐ 这是 **closed-form analytical solution**；不需要迭代。

3.4 Worked example：simple linear regression

数据：`(1,2), (2,4), (3,5)`。

```
mean x = 2
mean y = 11/3 ≈ 3.667
Sxx = Σ(x - mean x)² = 1 + 0 + 1 = 2
Sxy = Σ(x - mean x)(y - mean y)
    = (-1)(-1.667) + 0 + (1)(1.333)
    = 3.0
slope θ1 = Sxy / Sxx = 3/2 = 1.5
intercept θ0 = mean y - θ1 * mean x
             = 3.667 - 1.5*2 = 0.667
```

So：

```
y_hat = 0.667 + 1.5 x
```

Predictions：`[2.167, 3.667, 5.167]`；residuals `[-0.167, 0.333, -0.167]`。

3.5 Ridge and Lasso

Ridge（L2）：

```
J(θ) = ||y - Fθ||² + λ ||θ||²
θ_hat = (FᵀF + λI)⁻¹ Fᵀy
```

- λ > 0：shrink weights，处理 `m ≥ N` / singular `FᵀF`；
- λ too large → underfit。

Lasso（L1）：

```
J(θ) = ||y - Fθ||² + λ Σ|θ_k|
```

- 倾向把不重要系数压到 **exactly 0** → feature selection；
- 无 closed-form，需数值优化。

⭐ Ridge vs Lasso：Ridge 缩小权重；Lasso 稀疏化（部分权重为 0）。

3.6 Regression metrics

Metric	Formula	Meaning
MSE	`(1/N) Σ (y - y_hat)²`	均方误差
RMSE	`sqrt(MSE)`	与 y 同量纲
MAE	`(1/N) Σ abs(y - y_hat)`	平均绝对误差
R^2	`1 - RSS/TSS`	拟合优度；越接近 1 越好
Adjusted R^2	`1 - (1-R²)(N-1)/(N-p-1)`	惩罚 feature 数

- `RSS = Σ(y - y_hat)²`；
- `TSS = Σ(y - mean y)²`。

3.7 Exam traps

Trap	Correct
OLS 需要迭代	❌ 有 closed-form normal equation
Ridge 会把系数压到 0	❌ Lasso 才会；Ridge 只是 shrink
R^2 越大一定越好	❌ 加 feature 会虚高；用 adjusted R^2
Regression target 是类别	❌ regression 是 continuous target
`L=(y-F)²` 的残差就是 y-F	❌ 是 2(y-F)；1/2 版本才是 y-F

4. Feature Selection（特征选择）— Slide 9

4.1 Key terms

English term	中文
curse of dimensionality	维数灾难
data sparsity	数据稀疏
distance concentration	距离集中
feature selection	特征选择（选子集）
feature extraction	特征提取（造新 feature）
peaking phenomenon	峰值现象
Fisher's ratio	Fisher 比率
mutual information	互信息
exhaustive search	穷举搜索
sequential forward selection	顺序前向选择
sequential backward elimination	顺序后向消除
filter method	过滤法
wrapper method	包装法
embedded method	嵌入式
Mahalanobis distance	马氏距离
scatter matrix	散布矩阵
relevance / redundancy	相关性/冗余

4.2 Curse of dimensionality

Two main aspects：

1. **Data sparsity**：高维空间中样本太少，覆盖不了空间；
2. **Distance concentration**：高维空间中 pairwise distances 趋于相同，"同类近、异类远"失效。

Why reduce features：

- **Computational complexity**：more features → more parameters；
- **Generalization**：`n_samples / n_parameters` 越高越好；features 多 → 参数多 → overfit。

4.3 Peaking phenomenon

- 横轴 feature 数，纵轴 error；
- 先增加 feature → error 下降；
- 超过 critical value `L` → error 上升；

- **更多 training samples → 更大的 L 和更好的 peak performance**。

⭐ 结论：小数据用少 feature；大数据可用更多 feature。

4.4 Feature selection vs extraction

	Feature selection	Feature extraction
做法	选 subset	变换生成新 feature
保留原 feature	✅	❌
例子	选 x1, x3	**PCA**
优点	可解释	压缩效率高

4.5 Fisher's ratio

For a binary problem, continuous feature：

```
Fisher = (m1 - m2)² / (s1² + s2²)
```

- `m1,m2`： class means；
- `s1²,s2²`： class variances；
- **larger → more discriminative**；
- 要求 continuous feature（不能直接用于 nominal）。

Example： m1=2, $s1^2$=1; m2=6, $s2^2$=4：

```
Fisher = (2-6)² / (1+4) = 16/5 = 3.2
```

4.6 Mutual information

```
I(X;Y) = H(X) + H(Y) - H(X,Y)
```

- 衡量 feature X 与 class Y 的 dependence；
- **larger → more relevant**；
- 常用于 discrete/categorical；continuous 可先 discretize（bin）。

4.7 Feature subset selection

Why not top-k? Top-ranked features may be highly correlated/redundant；good subset = **maximum relevance + minimum redundancy**。

Search algorithms：

Method	Procedure	Note
Exhaustive	all subsets	optimal but combinatorial
Sequential forward	start empty; add best feature each step	bottom-up
Sequential backward	start full; remove least important each step	top-down

Evaluation criteria：

- **Wrapper**： train a classifier on each subset; use validation accuracy/error；
- accurate/matched to classifier, but expensive.
- **Filter**： use separability measure, no classifier；
- **Mahalanobis distance**： `(m1-m2)ᵀ C⁻¹ (m1-m2)` ；
- **Scatter**： `trace(Sw⁻¹ Sb)` or `trace(Sb)/trace(Sw)` ；
- fast, but distribution assumptions.

Embedded：

- Model has built-in feature selection；
- **Lasso**： L1 penalty shrinks unimportant coefficients to 0.

4.8 Exam traps

Trap	Correct
选 top-k 就是好 subset	❌ 可能高度冗余
Fisher 可用于 categorical	❌ 需要均值和方差，连续特征
Filter 需要训练 classifier	❌ wrapper 才训练
Lasso 是 filter	❌ embedded
Peaking：feature 越多越好	❌ 先降后升
Mutual information 越大越不相关	❌ 越大越相关

---

5. K-means Clustering（K-means 聚类）— Slide 10

5.1 Key terms

English term	中文
clustering	聚类
cluster	簇
centroid	质心
within-cluster sum of squares (WCSS)	簇内平方和
assignment step	分配步
update step	更新步
convergence	收敛
elbow method	肘部法
K	簇数
Minkowski distance	闵可夫斯基距离
Euclidean distance	欧氏距离
Manhattan distance	曼哈顿距离
cosine similarity	余弦相似度

5.2 Distance metrics

Minkowski distance：

```
d(x, x') = ( Σ_k |x_k - x'_k|^q )^(1/q)
```

- q=2 → **Euclidean**；
- q=1 → **Manhattan / city-block**；
- **Mahalanobis** 考虑 feature correlation；
- **Cosine similarity**：`xᵀx' / (||x|| ||x'||)`，越大越相似。

5.3 K-means objective

```
WCSS = Σ_k Σ_{x ∈ C_k} ||x - μ_k||²
```

- `C_k`：第 k 个 cluster；
- `μ_k`：第 k 个 centroid；
- K-means 最小化 WCSS。

5.4 Algorithm（two operations per iteration）

1. 选择 K；

2. 初始化 K 个 centroids（random / random samples）；
3. **Assignment step**：每个 sample 分到**最近的 centroid**；
4. **Update step**：每个 cluster 的新 centroid = 该 cluster 所有 sample 的**均值**；
5. 重复 3–4，直到 **centroid 不再变化** / **assignment 不再变化**。

5.5 Worked example 1（1D）

Data：`[1, 2, 3, 10, 11, 12]`，K=2，initial centroids `μ1=1, μ2=12`。

Iteration 1 — assignment：

- 1,2,3 → closer to 1 → C1；
- 10,11,12 → closer to 12 → C2。

Iteration 1 — update：

```
μ1 = mean(1,2,3) = 2
μ2 = mean(10,11,12) = 11
```

Iteration 2 — assignment：same assignment（1,2,3 → 2；10,11,12 → 11）。

Iteration 2 — update：μ1=2, μ2=11 → unchanged → **converged**.

5.6 Worked example 2（2D）

Data：`A(1,1), B(2,1), C(4,3), D(5,4)`；K=2；initial centroids `μ1=(1,1)`, `μ2=(5,4)`。

Assignment：

Point	Distance to μ1	Distance to μ2	Cluster
A(1,1)	0	√(16+9)=5	C1
B(2,1)	1	√(9+9)=4.24	C1
C(4,3)	√(9+4)=3.61	√(1+1)=1.41	C2
D(5,4)	5	0	C2

Update：

```
μ1 = mean(A,B) = (1.5, 1)
μ2 = mean(C,D) = (4.5, 3.5)
```

Next assignment：A,B stay C1；C,D stay C2 → converged.

5.7 Choosing K：Elbow method

- For K=1,2,3,... run K-means；compute WCSS；
- Plot WCSS vs K；
- WCSS always decreases with K（K=N → 0）；
- Find the **elbow** where the decrease becomes slow；
- That K is a reasonable choice。

5.8 Limitations

- Assumes **spherical/compact clusters**；
- Sensitive to **initialization**（local minima）；
- Must choose K；
- Sensitive to **feature scaling**；
- Sensitive to **outliers**。

5.9 Exam traps

Trap	Correct
K-means 是有监督	❌ unsupervised
K-means 最大化 WCSS	❌ minimize
每次迭代只做 assignment	❌ assignment + update
WCSS 随 K 增加而增加	❌ 下降
K-means 适合任意形状 cluster	❌ 球形/紧凑
K-means 对初始化不敏感	❌ 敏感，可能 local minimum

6. Formula Sheet（考前速记）

```
Entropy:        i_E = -Σ p_j log2 p_j
Gini:           i_Gini = 1 - Σ p_j²  (or (1/2)[1-Σp_j²])
Misclass:       i_MC = 1 - max p_j
Impurity drop:  Δi = i(N) - P_L i(N_L) - P_R i(N_R)
Gain ratio:     Δi' = Δi / (-Σ P_k log2 P_k)

Accuracy:       (TP+TN)/N
Error rate:     (FP+FN)/N
Sensitivity:    TP/(TP+FN) = Recall
Specificity:    TN/(TN+FP)
Precision:      TP/(TP+FP)
F1:             2PR/(P+R)
TPR:            TP/(TP+FN)
FPR:            FP/(FP+TN) = 1 - Specificity

OLS:            θ_hat = (FᵀF)⁻¹Fᵀy
Ridge:          θ_hat = (FᵀF + λI)⁻¹Fᵀy
Lasso:          J = ||y-Fθ||² + λΣ|θ|
MSE:            (1/N)Σ(y-ŷ)²
RMSE:           sqrt(MSE)
MAE:            (1/N)Σ|y-ŷ|
R²:             1 - RSS/TSS

Fisher:         (m1-m2)²/(s1²+s2²)
MI:             H(X)+H(Y)-H(X,Y)
Mahalanobis:    (m1-m2)ᵀ C⁻¹ (m1-m2)
Scatter:        trace(Sw⁻¹Sb) or trace(Sb)/trace(Sw)

K-means WCSS:   Σ_k Σ_{x∈C_k} ||x-μ_k||²
Minkowski:      (Σ|x_k-x'_k|^q)^(1/q)
```

---

7. Practice Questions（含答案）

Q1（Gini）

A node has 10 samples, 5 positive / 5 negative. After a split: left 4 positive + 1 negative; right 1 positive + 4 negative. Compute Gini gain.

Answer：

```
G_parent = 1 - 0.5² - 0.5² = 0.5
G_left = 1 - 0.8² - 0.2² = 0.32
G_right = 0.32
G_after = 0.5*0.32 + 0.5*0.32 = 0.32
ΔG = 0.5 - 0.32 = 0.18
```

Q2（Entropy）

Same split；compute entropy gain.

Answer：

```
H_parent = 1
H_left = H_right = -0.8log2 0.8 - 0.2log2 0.2 ≈ 0.7219
H_after ≈ 0.7219
ΔH = 1 - 0.7219 = 0.2781
```

Q3（Confusion matrix）

TP=85, FP=4, FN=2, TN=9. Compute accuracy, sensitivity, specificity, precision, recall, F1.

Answer：

```
Accuracy = (85+9)/100 = 94%
Sensitivity = 85/87 ≈ 97.7%
Specificity = 9/13 ≈ 69.2%
Precision = 85/89 ≈ 95.5%
Recall = 85/87 ≈ 97.7%
F1 = 2*0.955*0.977/(0.955+0.977) ≈ 0.966
```

Q4（OLS）

Data `(1,2),(2,4),(3,5)`. Find OLS line.

Answer：

```
mean x = 2; mean y = 3.667
Sxx = 2; Sxy = 3
slope = 1.5; intercept = 0.667
y_hat = 0.667 + 1.5x
```

Q5（Ridge）

For `FᵀF = [[2,0],[0,2]]`, `Fᵀy = [4,6]`, $\lambda=2$. Find ridge θ.

Answer：

```
(FᵀF + λI) = [[4,0],[0,4]]
θ = [[4,0],[0,4]]⁻¹ [4,6] = [1, 1.5]
```

Q6（Feature selection）

Class 1: mean=2, variance=1; Class 2: mean=6, variance=4. Compute Fisher's ratio.

Answer：

```
Fisher = (2-6)² / (1+4) = 16/5 = 3.2
```

Q7（K-means）

Data `[1,2,3,10,11,12]`, K=2, initial centroids 1 and 12. Do one iteration.

Answer：

```
Assignment: {1,2,3}→C1, {10,11,12}→C2
Update: μ1=2, μ2=11
```

Q8（Elbow）

WCSS for K=1..5: 100, 60, 45, 42, 40. Which K by elbow?

Answer：K=3（从 60→45 降幅大，45→42 明显变小）。

---

8. Last-minute Checklist

- [ ] Gini / entropy / impurity drop 公式能默写。
- [ ] 连续 feature 的 split 步骤：sort → midpoints → test each。
- [ ] Confusion matrix 四种情况 + 所有指标公式。
- [ ] ROC 横轴 FPR、纵轴 TPR；AUC 含义。
- [ ] OLS normal equation；ridge 加 λI；lasso 稀疏。
- [ ] MSE/RMSE/MAE/R^2 公式。
- [ ] Fisher's ratio；mutual information。
- [ ] filter vs wrapper vs embedded。
- [ ] K-means 两步：assignment + update；WCSS 最小化。
- [ ] Elbow method。
- [ ] 英文术语：impurity, split, confusion matrix, precision, recall, OLS, ridge, lasso, Fisher's ratio, mutual information, within-cluster sum of squares。

> **一句话**：Quiz 2 = **Gini/entropy 计算 + confusion matrix 指标 + OLS/ridge + Fisher/MI + K-means 手算**；40 分钟，先做会的，计算题写公式再代数字。